

# Faster R-CNN : 通过 Region Proposal 网络实现实时目标检测

Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun

## 摘要

最先进的目标检测网络依靠 region proposal 算法来推理检测目标的位置。SPPnet[1]和 Fast R-CNN[2]等类似的研究已经减少了这些检测网络的运行时间，使得 region proposal 计算成为一个瓶颈。在这项工作中，我们引入了一个 region proposal 网络（RPN），该网络与检测网络共享整个图像的卷积特征，从而使近乎零成本的 region proposal 成为可能。RPN 是一个全卷积网络，可以同时在每个位置预测目标边界和目标分数。RPN 经过端到端的训练，可以生成高质量的 region proposal，并使用 Fast R-CNN 完成检测。我们将 RPN 和 Fast R-CNN 通过共享卷积特征进一步合并为一个单一的网络——使用最近流行的具有“注意力”机制的神经网络术语，RPN 组件告诉统一网络在哪里寻找。对于非常深的 VGG-16 模型[3]，我们的检测系统在 GPU 上的帧率为 5fps（包括所有步骤），同时在 PASCAL VOC 2007、2012 和 MS COCO 数据集上达到了目前最好的目标检测精度，每个图像只有 300 个 proposals。在 ILSVRC 和 COCO 2015 竞赛中，Faster R-CNN 和 RPN 是多个比赛中获得第一名的基础。代码已公开。

## 关键字

目标检测，Region Proposal，卷积神经网络

## 1. 引言

目标检测的最新进展是由 region proposal 方法（例如[4]）和基于区域的卷积神经网络（R-CNN）[5]的成功驱动的。尽管在[5]中最初开发的基于区域的 CNN 计算代价很大，但是由于在各种 proposals 中共享卷积，所以其成本已经大大降低了[1]，[2]。忽略花费在 region proposals 上的时间，最新版本 Fast R-CNN[2]利用非常深的网络[3]实现了接近实时的速率。现在，proposals 是最新的检测系统中测试时间的计算瓶颈。

Region proposal 方法通常依赖廉价的特征和简练的推断方案。Selective Search [4]是最流行的方法之一，它贪婪地合并基于设计的低级特征的超级像素。然而，与有效的检测网络[2]相比，Selective Search 速度慢了一个数量级，在 CPU 实现中每张图像的时间为 2 秒。EdgeBoxes[6]目前提出了在 proposal 质量和速度之间的最佳权衡，每张图像 0.2 秒。尽管如此，region proposal 步骤仍然像检测网络那样消耗同样多的运行时间。

有人可能会注意到，基于区域的快速 CNN 利用 GPU，而在研究中使用的 region proposal 方法在 CPU 上实现，使得运行时间比较不公平。加速 region proposal 计算的一个显而易见的方法是将其在 GPU 上重新实现。这可能是一个有效的工程解决方案，但重新实现忽略了下游检测网络，因此错过了共享计算的重要机会。

在本文中，我们展示了算法的变化——用深度卷积神经网络计算 region proposal——获得了一个优雅和有效的解决方案，其中在给定检测网络计算的情况下 region proposal 计算接近零成本。为此，我们

引入了新的 region proposal 网络（RPN），它们共享最先进目标检测网络的卷积层[1], [2]。通过在测试时共享卷积，计算 region proposal 的边际成本很小（例如，每张图像仅需 10ms）。

我们的观察到基于区域的检测器所使用的卷积特征映射，如 Fast R-CNN，也可以用于生成 region proposal。在这些卷积特征之上，我们通过添加一些额外的卷积层来构建 RPN，这些卷积层同时在规则网格上的每个位置上回归区域边界和目标分数。因此 RPN 是一种全卷积网络（FCN）[7]，可以针对生成检测区域 proposals 的任务进行端到端的训练。

RPN 旨在有效预测具有广泛尺度和长宽比的 region proposal。与使用图像金字塔（图 1 a）或滤波器金字塔（图 1 b）的流行方法[8], [9], [1], [2]相比，我们引入新的“anchor”框作为多种尺度和长宽比的参考。我们的方案可以被认为是回归参考金字塔（图 1 c），它避免了遍历多种比例或长宽比的图像或滤波器。这个模型在使用单尺度图像进行训练和测试时运行良好，从而有利于提升运行速度。




图 1: 解决多尺度和尺寸的不同方案。(a) 构建图像和特征映射金字塔，分类器以各种尺度运行。(b) 在特征映射上运行具有多个比例/大小的滤波器的金字塔。(c) 我们在回归函数中使用参考边界框金字塔。

为了将 RPN 与 Fast R-CNN [2]目标检测网络相结合，我们提出了一种训练方案，在 fine-tune region proposal 任务和 fine-tune 目标检

测之间进行交替,同时保持 region proposal 的固定。该方案快速收敛,并产生两个任务之间共享的具有卷积特征的统一网络。

我们在 PASCAL VOC 检测基准数据集上[11]综合评估了我们的方法,其中具有 Fast R-CNN 的 RPN 产生的检测精度优于使用 Selective Search 的 Fast R-CNN 的强基准模型。同时,我们的方法在测试时几乎免除了 Selective Search 的所有计算负担——region proposal 的有效运行时间仅为 10 毫秒。使用[3]的昂贵的非常深的模型,我们的检测方法在 GPU 上仍然具有 5fps 的帧率(包括所有步骤),因此在速度和准确性方面是实用的目标检测系统。我们还报告了在 MS COCO 数据集上[12]的结果,并使用 COCO 数据研究了在 PASCAL VOC 上的改进。代码可公开获得 [https://github.com/shaoqingren/faster\\_rcnn](https://github.com/shaoqingren/faster_rcnn) (MATLAB 实现) 和 <https://github.com/rbgirshick/py-faster-rcnn> (Python 实现)。

这篇稿件的初始版本是以前发表的[10]。从那时起,RPN 和 Faster R-CNN 的框架已经被采用并推广到其他方法,如 3D 目标检测[13],基于部件的检测[14],实例分割[15]和图像标题生成[16]。我们快速和有效的目标检测系统也已经在 Pinterest[17]的商业系统中进行了部署,并报告了用户参与度的提高。

在 ILSVRC 和 COCO 2015 竞赛中,Faster R-CNN 和 RPN 是 ImageNet 检测任务、ImageNet 定位任务、COCO 检测任务和 COCO 分割任务中几个第一名获胜模型[18]的基础。RPN 完全从数据中学习 propose regions,因此可以从更深入和更具表达性的特征(例如[18]中

采用的 101 层残差网络) 中轻松获益。Faster R-CNN 和 RPN 也被这些比赛中的其他几个主要参赛者所使用。这些结果表明, 我们的方法不仅是一个实用合算的解决方案, 而且是一个提高目标检测精度的有效方法。

## 2. 相关研究工作

**目标 Proposals。**目标 **Proposals** 方法方面有大量的文献。目标 **Proposals** 方法的综合调查和比较可以在[19], [20], [21]中找到。广泛使用的目标提议方法包括基于超像素分组(例如, Selective Search [4], CPMC[22], MCG[23])和那些基于滑动窗口的方法(例如窗口中的目标[24], EdgeBoxes[6])。目标提议方法被采用为独立于检测器(例如, Selective Search [4]目标检测器, R-CNN[5]和 Fast R-CNN[2])的外部模块。

**用于目标检测的深度网络。**R-CNN 方法[5]端到端地对 CNN 进行训练, 将 proposal regions 分类为目标类别或背景。R-CNN 主要作为分类器, 并不能预测目标边界(除了通过边界框回归进行修正)。其准确度取决于 region proposal 模块的性能(参见[20]中的比较)。一些论文提出了使用深度网络来预测目标边界框的方法[25], [9], [26], [27]。在 OverFeat 方法[9]中, 训练一个全连接层来预测假定单个目标定位任务的边界框坐标。然后将全连接层变成卷积层, 用于检测多个类别的目标。MultiBox 方法[26], [27]从网络中生成 region proposal, 网络最后的全连接层同时预测多个类别不相关的边界框, 并推广到 OverFeat 的“单边界框”方式。这些类别不可知的边界框被用作 R-

CNN 的候选区域[5]。与我们的全卷积方案相比，MultiBox 提议网络适用于单张裁剪图像或多张大型裁剪图像（例如  $224 \times 224$ ）。MultiBox 在提议区域和检测网络之间不共享特征。稍后在介绍我们的方法时会讨论 OverFeat 和 MultiBox。与我们的工作同时进行的 DeepMask 方法[28]是为学习分割 proposals 而开发的。

卷积[9]，[1]，[29]，[7]，[2]的共享计算已经越来越受到人们的关注，因为它可以有效而准确地进行视觉识别。OverFeat 论文[9]计算图像金字塔的卷积特征用于分类、定位和检测。共享卷积特征映射的自适应大小池化（SPP）[1]被开发用于有效的基于区域的目标检测[1]，[30]和语义分割[29]。Fast R-CNN[2]能够对共享卷积特征进行端到端的检测器训练，并显示出令人信服的准确性和速度。

### 3. FASTER R-CNN

我们的目标检测系统，称为 Faster R-CNN，由两个模块组成。第一个模块是产生 proposes regions 的深度全卷积网络，第二个模块是使用 proposes regions 的 Fast R-CNN 检测器[2]。整个系统是一个单独的、统一的目标检测网络（图 2）。使用最近流行的“注意力”[31]机制的神经网络术语，RPN 模块告诉 Fast R-CNN 模块在哪里寻找。在第 3.1 节中，我们介绍了 region proposal 网络的设计和属性。在第 3.2 节中，我们开发了用于训练具有共享特征的两个模块算法。

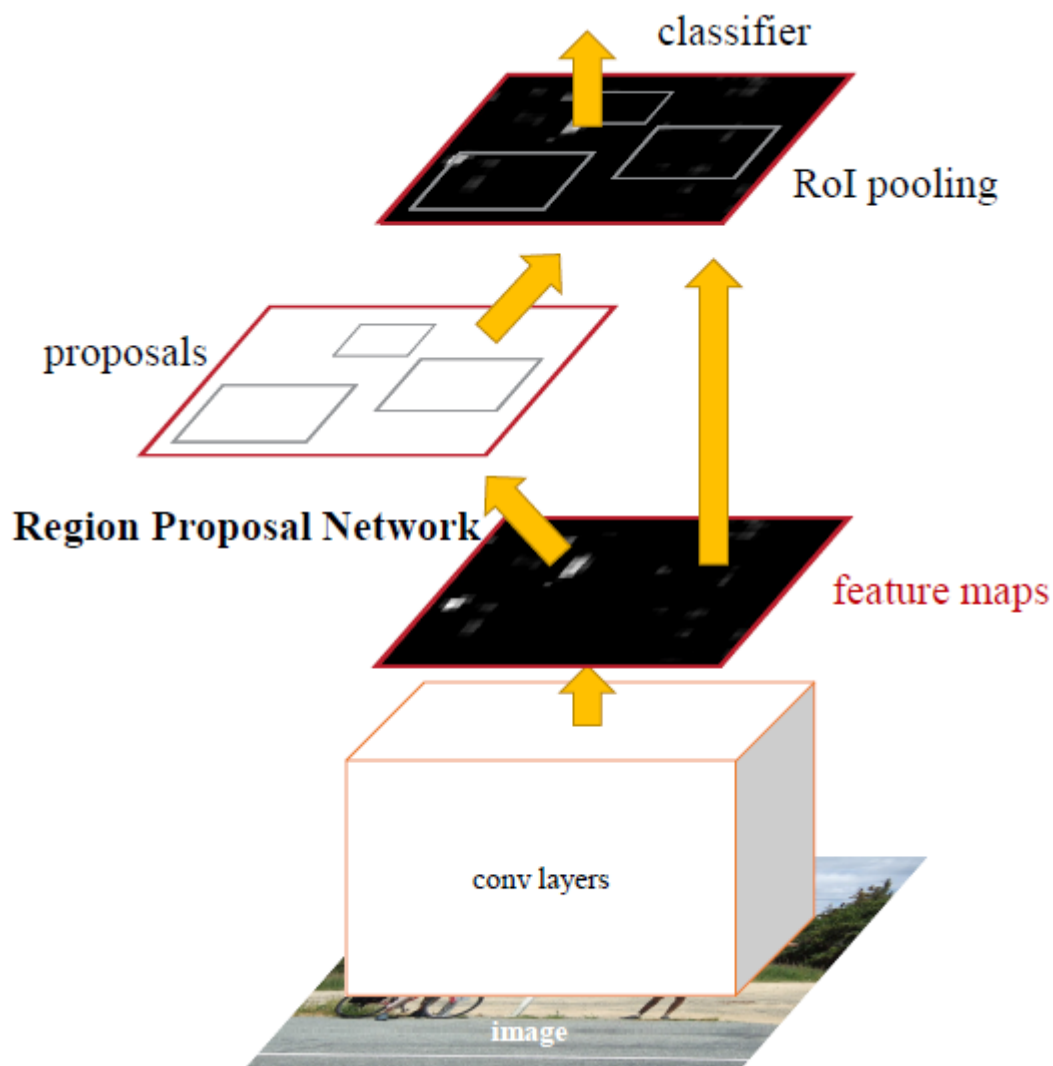


图 2: Faster R-CNN 是一个单一、统一的目标检测网络。RPN 模块作为这个统一网络的“注意力”。

### 3.1 region proposal 网络

region proposal 网络 (RPN) 以任意大小的图像作为输入，输出一组矩形的目标 proposals，每个 proposals 都有一个目标得分。我们用全卷积网络[7]对这个过程进行建模，我们将在本节进行描述。因为我们的最终目标是与 Fast R-CNN 目标检测网络[2]共享计算，所以我们假设两个网络共享一组共同的卷积层。在我们的实验中，我们研究了具有 5 个共享卷积层的 Zeiler 和 Fergus 模型[32] (ZF) 和具有 13 个共享卷积层的 Simonyan 和 Zisserman 模型[3] (VGG-16)。



为了生成 region proposal，我们在最后的共享卷积层输出的卷积特征映射上滑动一个小网络。这个小网络将输入卷积特征映射的  $n \times n$  空间窗口作为输入。每个滑动窗口映射到一个低维特征（ZF 为 256 维，VGG 为 512 维，后面是 ReLU[33]）。这个特征被输入到两个子全连接层——一个边界框回归层（reg）和一个边界框分类层（cls）。在本文中，我们使用  $n=3$ ，注意输入图像上的有效感受野是大的（ZF 和 VGG 分别为 171 和 228 个像素）。图 3（左）所示为这个小型网络。请注意，因为小网络以滑动窗口方式运行，所以所有空间位置共享全连接层。这种架构通过一个  $n \times n$  卷积层、后面接两个子  $1 \times 1$  卷积层（分别用于 reg 和 cls）自然地实现了。

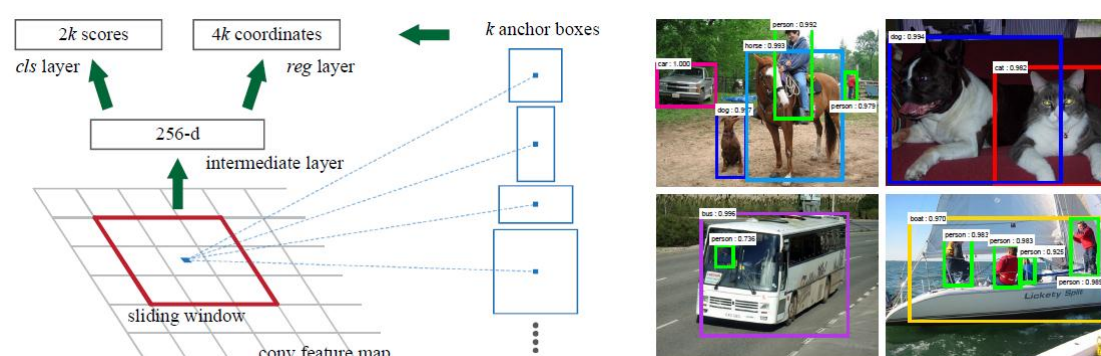


图 3: 左图为 region proposal 网络（RPN）。右图为 PASCAL VOC 2007 测试集上使用 RPN 提议的示例检测。我们的方法可以检测各种尺度和长宽比的目标。

### 3.1.1 Anchors

在每个滑动窗口位置，我们同时预测多个 region proposal，其中每个位置可能候选的最大数目表示为  $k$ 。因此，reg 层具有  $4k$  个输出，分别编码  $k$  个边界框的坐标，cls 层输出  $2k$  个得分值，分别估计每个提议是目标或不是目标的概率。相对于我们称之为 anchors 的  $k$  个参考边界框， $k$  个 proposals 是参数化的（译者注：也就是说进行了初始化，可能与 ground truth 有一定的差距，但可以通过反向传播进行修



正或调整)。anchors 位于所讨论的滑动窗口的中心，并且具有一定的尺度和长宽比（图 3 左）。默认情况下，我们使用 3 个尺度和 3 个长宽比，在每个滑动位置产生  $k=9$  个 anchors。对于大小为  $W \times H$ （通常为 2400）的卷积特征映射，总共有  $WHk$  个 anchors。

### 平移不变的 Anchors

我们的方法的一个重要特性是它是平移不变的，无论是在 anchors 还是计算相对于 anchors 的 region proposal 的函数。如果在图像中平移目标，proposal 应该平移，并且同样的函数应该能够在任一位置预测 proposal。平移不变特性是由我们的方法保证的。作为对比，MultiBox 方法[27]使用 k-means 生成 800 个 anchors，这不是平移不变的。所以如果平移目标，MultiBox 不保证会生成相同的 proposal。

平移不变特性也减小了模型的大小。MultiBox 有  $(4+1) \times 800$  维的全连接输出层，而我们的方法在  $k=9$  个 anchors 的情况下有  $(4+2) \times 9$  维的卷积输出层。因此，我们的输出层具有  $2.8 \times 10^4$  个参数（其中 VGG-16 为  $512 \times (4+2) \times 9$  个），比 MultiBox 输出层的  $6.1 \times 10^6$  个参数少了两个数量级（其中 MultiBox [27]中的 GoogleNet[34]为  $1536 \times (4+1) \times 800$  个）。如果考虑到特征投影层，我们的 proposal 层仍然比 MultiBox 少一个数量级。我们期望我们的方法在 PASCAL VOC 等小数据集上有更小的过拟合风险。

### 多尺度 Anchors 作为回归参考

我们的 anchors 设计提出了一个新的方案来解决多尺度（和长宽比）。如图 1 所示，多尺度预测有两种流行的方法。第一种方法是基

于图像/特征金字塔，例如 DPM[8]和基于 CNN 的方法[9], [1], [2]。图像在多个尺度上进行缩放，并且针对每个尺度（图 1（a））计算特征映射（HOG[8]或深卷积特征[9], [1], [2]）。这种方法通常是有用的，但是非常耗时。第二种方法是在特征映射上使用多尺度（和/或长宽比）的滑动窗口。例如，在 DPM[8]中，使用不同的滤波器大小（例如  $5 \times 7$  和  $7 \times 5$ ）分别对不同长宽比的模型进行训练。如果用这种方法来解决多尺度问题，可以把它看作是一个“滤波器金字塔”（图 1(b)）。第二种方法通常与第一种方法联合采用[8]。

作为比较，我们基于 anchor 的方法建立在 anchors 金字塔上，这是更加高效的方法。我们的方法参照多尺度和长宽比的 anchor 框来分类和回归边界框。它只依赖单一尺度的图像和特征映射，并使用单一尺寸的滤波器（特征映射上的滑动窗口）。我们通过实验来展示这个方案解决多尺度和尺寸的效果（表 8）。

**表 8: Faster R-CNN 在 PAS-CAL VOC 2007 测试数据集上使用不同 anchors 设置的检测结果。**网络是 VGG-16。训练数据是 VOC 2007 训练集。使用 3 个尺度和 3 个长宽比（69.9%）的默认设置，与表 3 中的相同。

settings	anchor scales	aspect ratios	mAP (%)
1 scale, 1 ratio	$128^2$	1:1	65.8
	$256^2$	1:1	66.7
1 scale, 3 ratios	$128^2$	{2:1, 1:1, 1:2}	68.8
	$256^2$	{2:1, 1:1, 1:2}	67.9
3 scales, 1 ratio	{ $128^2, 256^2, 512^2$ }	1:1	69.8
3 scales, 3 ratios	{ $128^2, 256^2, 512^2$ }	{2:1, 1:1, 1:2}	69.9

由于这种基于 anchors 的多尺度设计，我们可以简单地使用在单尺度图像上计算的卷积特征，Fast R-CNN 检测器也是这样做的[2]。

多尺度 anchors 设计是共享特征的关键组件，不需要额外的成本来处理尺度。

### 3.1.2 损失函数

为了训练 RPN，我们为每个 anchor 分配一个二值类别标签（是目标或不是目标）。我们给这两种 anchor 分配一个正样本标签：(i) 具有与实际边界框的重叠最高交并比（IoU）的 anchor，或者 (ii) 具有与实际边界框的重叠超过 0.7 IoU 的 anchor。注意，单个真实边界框可以为多个 anchor 分配正标签。通常第二个条件足以确定正样本；但我们仍然采用第一个条件，因为在一些极少数情况下，第二个条件可能找不到正样本。对于所有的真实边界框，如果一个 anchor 的 IoU 比率低于 0.3，我们给非正样本的 anchor 分配一个负标签。既不是正样本标签也不是负样本标签的 anchor 对训练目标函数没有作用。

根据这些定义，我们根据 Fast R-CNN[2]中的多任务损失对目标函数进行最小化。我们对某一个图像的损失函数定义为：

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*). \quad (1)$$

其中， $i$  是小批量数据中 anchor 的索引， $p_i$  表示 anchor  $i$  是目标的预测概率。如果 anchor 为正样本标签，则真实标签  $p_i^*$  为 1，如果 anchor 为负样本标签，则为 0。 $t_i$  是表示预测边界框的 4 个参数化坐标组成的向量，而  $t_i^*$  是与正标签 anchor 相关联的真实边界框坐标组成的向量。分类损失  $L_{cls}$  是两个类别上（是目标或不是目标）的对数损失。

对于回归损失，我们使用  $L_{reg}(t_i, t^*_i) = R(t_i - t^*_i)$ ，其中  $R$  是在[2]中定义的鲁棒损失函数（L1 平滑函数）。 $p_i L_{reg}$  项表示回归损失仅对于正样本  $anchor$ （ $p_i=1$ ）有效，否则无效（ $p_i=0$ ）。 $cls$  和  $reg$  层的输出分别由  $p_i$  和  $t_i$  组成。

这两个项用  $N_{cls}$  和  $N_{reg}$  进行标准化，并由一个平衡参数  $\lambda$  加权。在我们目前的实现中（如在发布的代码中），方程（1）中的  $cls$  项通过小批量数据的大小（即  $N_{cls}=256$ ）进行归一化， $reg$  项根据  $anchor$  位置的数量（即  $N_{reg} \sim 24000$ ）进行归一化。默认情况下，我们设置  $\lambda=10$ ，因此  $cls$  和  $reg$  项的权重大致相等。我们通过实验表明，结果对宽范围的  $\lambda$  值不敏感(表 9)。我们还注意到，上面的归一化不是必需的，可以简化。

**表 9: Faster R-CNN 使用方程(1)中不同的  $\lambda$  值在 PASCAL VOC 2007 测试集上的检测结果。**网络是 VGG-16。训练数据是 VOC 2007 训练集。使用  $\lambda=10$  (69.9%) 的默认设置与表 3 中的相同。

$\lambda$	0.1	1	10	100
mAP (%)	67.2	68.9	69.9	69.1

对于边界框回归，我们采用[5]中的 4 个坐标参数化：

$$\begin{aligned}
 t_x &= (x - x_a)/w_a, & t_y &= (y - y_a)/h_a, \\
 t_w &= \log(w/w_a), & t_h &= \log(h/h_a), \\
 t_x^* &= (x^* - x_a)/w_a, & t_y^* &= (y^* - y_a)/h_a, \\
 t_w^* &= \log(w^*/w_a), & t_h^* &= \log(h^*/h_a),
 \end{aligned} \tag{2}$$

其中， $x$ 、 $y$ 、 $w$ 、 $h$  表示边界框的中心坐标及其宽和高。变量  $x$ 、 $x_a$  和  $x^*$  分别表示预测边界框、 $anchor$  框和边界框真值（类似于  $y$ 、 $w$ 、 $h$  与其类似）。这可以被认为是从  $anchor$  框到相近实际边界框的回归。

然而，我们的方法通过与之前的基于 RoI（感兴趣区域）方法[1][2]不同的方式来实现边界框回归。在[1]，[2]中，对任意大小的 RoI 池化的特征执行边界框回归，并且回归权重由所有区域大小共享。在我们的公式中，用于回归的特征在特征映射上具有相同的空间大小（ $3 \times 3$ ）。为了说明不同的大小，学习一组  $k$  个边界框回归器。每个回归器负责一个尺度和一个长宽比，而  $k$  个回归器不共享权重。因此，由于 anchor 的设计，即使特征具有固定的尺度/比例，仍然可以预测各种尺寸的边界框。

### 3.1.3 训练 RPN

RPN 可以通过反向传播和随机梯度下降（SGD）进行端对端训练[35]。我们遵循[2]中的“图像中心”采样策略来训练这个网络。每个小批量数据都从包含许多正样本和负样本 anchor 的单张图像中产生。对所有 anchor 的损失函数进行优化是可能的，但是这样会偏向于负样本，因为它们是占大部分的。取而代之的是，我们在图像中随机采样 256 个 anchor，计算一个小批量数据的损失函数，其中采样的正 anchor 和负 anchor 的比率可达 1:1。如果图像中的正样本少于 128 个，我们使用负样本填充小批量数据。

我们通过从标准方差为 0.01 的零均值高斯分布中获得权重来随机初始化所有新层。所有其他层（即共享卷积层）通过预训练的 ImageNet 分类模型[36]来初始化，如同标准操作[5]。我们调整 ZF 网络的所有层，以及 VGG 网络的 conv3\_1 及其之上的层以节省内存[2]。对于 60k 的小批量数据，我们使用 0.001 的学习率，对于 PASCAL

VOC 数据集中的下一个 20k 小批量数据，使用 0.0001。我们使用 0.9 的动量和 0.0005 的重量衰减[37]。我们的实现使用 Caffe[38]。

### 3.2 RPN 和 Fast R-CNN 共享特征

到目前为止，我们已经描述了如何训练用于生成 region proposal 的网络，没有提及将如何利用这些 proposals 的基于区域的目标检测 CNN。对于检测网络，我们采用 Fast R-CNN[2]。接下来我们介绍一些算法，学习由 RPN 和 Fast R-CNN 组成的具有共享卷积层的统一网络（图 2）。

独立训练的 RPN 和 Fast R-CNN 将以不同的方式修改卷积层。因此，我们需要开发一种允许在两个网络之间共享卷积层的技术，而不是学习两个独立的网络。我们讨论三个方法来训练具有共享特征的网络：

**（1）交替训练。**在这个解决方案中，我们首先训练 RPN，并使用这些 proposals 来训练 Fast R-CNN。由 Fast R-CNN fine-tune 的网络然后被用于初始化 RPN，并且重复迭代这个过程。这是本文所有实验中使用的解决方案。

**（2）近似联合训练。**在这个解决方案中，RPN 和 Fast R-CNN 网络在训练期间合并成一个网络，如图 2 所示。在每次 SGD 迭代中，前向传递生成 region proposal，在训练 Fast R-CNN 检测器将这看作是固定的、预计算的提议。反向传播像往常一样进行，其中对于共享层，组合来自 RPN 损失和 Fast R-CNN 损失的反向传播信号。这个解决方案很容易实现。但是这个解决方案忽略了关于 proposals 边界框的坐



标（也是网络响应）的导数，因此是近似的。在我们的实验中，我们实验发现这个求解器产生了相当的结果，与交替训练相比，训练时间减少了大约 25-50%。这个求解器包含在我们发布的 Python 代码中。

**(3) 非近似的联合训练。**如上所述，由 RPN 预测的边界框也是输入的函数。Fast R-CNN 中的 RoI 池化层[2]接受卷积特征以及预测的边界框作为输入，所以理论上有效的反向传播求解器也应该包括关于边界框坐标的梯度。在上述近似联合训练中，这些梯度被忽略。在一个非近似的联合训练解决方案中，我们需要一个关于边界框坐标可微分的 RoI 池化层。这是一个重要的问题，可以通过[15]中提出的“RoI 扭曲”层给出解决方案，这超出了本文的范围。

**四步交替训练。**在本文中，我们采用实用的四步训练算法，通过交替优化学习共享特征。在第一步中，我们按照 3.1.3 节的描述训练 RPN。该网络使用 ImageNet 的预训练模型进行初始化，并针对 region proposal 任务进行了端到端的 fine-tune。在第二步中，我们使用由第一步 RPN 生成的提议，由 Fast R-CNN 训练单独的检测网络。该检测网络也由 ImageNet 的预训练模型进行初始化。此时两个网络不共享卷积层。在第三步中，我们使用检测器网络来初始化 RPN 训练，但是我们修正共享的卷积层，并且只对 RPN 特有的层进行 fine-tune。现在这两个网络共享卷积层。最后，保持共享卷积层的固定，我们对 Fast R-CNN 的独有层进行 fine-tune。因此，两个网络共享相同的卷积层并形成统一的网络。类似的交替训练可以运行更多的迭代，但是我们观察改进一只一点点，甚至可以忽略。

### 3.3 实现细节

我们在单尺度图像上训练和测试 region proposal 和目标检测网络 [1], [2]。我们再次缩放图像, 使得它们的短边是  $s=600$  像素[2]。多尺度特征提取(使用图像金字塔)可能会提高精度, 但不会表现出速度与精度的良好权衡[2]。在重新缩放的图像上, 最后卷积层上的 ZF 和 VGG 网络的总步长为 16 个像素, 因此在调整大小 ( $\sim 500 \times 375$ ) 之前, 典型的 PASCAL 图像上的总步长为  $\sim 10$  个像素。即使如此大的步长也能提供良好的效果, 尽管步幅更小, 精度可能会进一步提高。

对于 anchor, 我们使用了 3 个尺度, 边界框面积分别为  $128^2$ 、 $256^2$  和  $512^2$  个像素, 以及 1:1, 1:2 和 2:1 的长宽比。这些超参数不是针对特定数据集精心挑选的, 我们将在下一节中提供有关其作用的消融实验。如上所述, 我们的解决方案不需要图像金字塔或滤波器金字塔来预测多个尺度的区域, 节省了大量的运行时间。图 3 (右) 显示了我们的方法在广泛的尺度和长宽比方面的能力。表 1 显示了使用 ZF 网络的每个 anchor 学习到的平均提议大小。我们注意到, 我们的算法允许预测比基础感受野更大的结果。这样的预测不是不可能的——如果只有目标的中间部分是可见的, 那么仍然可以粗略地推断出目标的范围。

**表 1: 使用 ZF 网络的每个 anchor 学习到的平均提议大小 ( $s=600$  的数字)。**

anchor	$128^2, 2:1$	$128^2, 1:1$	$128^2, 1:2$	$256^2, 2:1$	$256^2, 1:1$	$256^2, 1:2$	$512^2, 2:1$	$512^2, 1:1$	$512^2, 1:2$
proposal	$188 \times 111$	$113 \times 114$	$70 \times 92$	$416 \times 229$	$261 \times 284$	$174 \times 332$	$768 \times 437$	$499 \times 501$	$355 \times 715$

跨越图像边界的 anchor 框需要谨慎处理。在训练过程中, 我们忽略了所有的跨边界的 anchor, 所以不会造成损失。对于一个典型的  $1000 \times 600$  的图片, 总共将会有大约 20000 ( $\approx 60 \times 40 \times 9$ ) 个 anchor。

跨界 anchor 被忽略，每张图像约有 6000 个 anchor 用于训练。如果跨边界异常值在训练中不被忽略，则会在目标函数中引入大的、难以纠正的误差项，且训练不会收敛。但在测试过程中，我们仍然将全卷积 RPN 应用于整张图像。当我们裁剪到图像边界时，可能会产生跨边界的 proposal 边界框。

一些 RPN proposals 互相之间高度重叠。为了减少冗余，我们在 proposals 区域根据他们的 cls 分类得分采取非极大值抑制（NMS）。我们将 NMS 的 IoU 阈值固定为 0.7，这就给每张图像留下了大约 2000 个 proposal regions。正如我们将要展示的那样，NMS 不会损害最终的检测准确性，但会大大减少 proposal 的数量。在 NMS 之后，我们使用前 N 个 proposal regions 来进行检测。接下来，我们使用 2000 个 RPN proposal 对 Fast R-CNN 进行训练，但在测试时评估不同数量的 proposal。

## 4. 实验

### 4.1 PASCAL VOC 上的实验

我们在 PASCAL VOC 2007 检测基准数据集[11]上全面评估了我们的方法。这个数据集包含大约 5000 张训练评估图像和在 20 个目标类别上的 5000 张测试图像。我们还提供了一些模型在 PASCAL VOC 2012 基准数据集上的测试结果。对于 ImageNet 预训练网络，我们使用具有 5 个卷积层和 3 个全连接层的 ZF 网络[32]的“快速”版本以及具有 13 个卷积层和 3 个全连接层的公开的 VGG-16 模型[3]。我们主

要评估检测的平均精度均值（mAP），因为这是检测目标的实际指标（而不是关注目标 proposal 代理指标）。

表 2（上面）显示了使用各种 region proposal 方法进行训练和测试的 Fast R-CNN 结果。这些结果使用 ZF 网络。对于 Selective Search（SS）[4]，我们通过“快速”模式生成约 2000 个 proposals。对于 EdgeBoxes（EB）[6]，我们通过调整 0.7 IoU 的默认 EB 设置生成 proposals。在 Fast R-CNN 框架下 SS 的 mAP 为 58.7%，EB 的 mAP 为 58.6%。RPN 与 Fast R-CNN 取得了有竞争力的结果，使用多达 300 个 proposals，mAP 为 59.9%。由于共享卷积计算，使用 RPN 比使用 SS 或 EB 产生了更快的检测系统；较少的 proposals 也减少了 region 方面的全连接层成本（表 5）。

**表 2: PASCAL VOC 2007 测试集上的检测结果**（在 VOC 2007 训练评估集上进行了训练）。检测器是带有 ZF 的 Fast R-CNN，但使用各种不同 proposal 方法进行训练和测试。

train-time region proposals		test-time region proposals		mAP (%)
method	# boxes	method	# proposals	
SS	2000	SS	2000	58.7
EB	2000	EB	2000	58.6
RPN+ZF, shared	2000	RPN+ZF, shared	300	59.9
<i>ablation experiments follow below</i>				
RPN+ZF, unshared	2000	RPN+ZF, unshared	300	58.7
SS	2000	RPN+ZF	100	55.1
SS	2000	RPN+ZF	300	56.8
SS	2000	RPN+ZF	1000	56.3
SS	2000	RPN+ZF (no NMS)	6000	55.2
SS	2000	RPN+ZF (no cls)	100	44.6
SS	2000	RPN+ZF (no cls)	300	51.4
SS	2000	RPN+ZF (no cls)	1000	55.8
SS	2000	RPN+ZF (no reg)	300	52.1
SS	2000	RPN+ZF (no reg)	1000	51.3
SS	2000	RPN+VGG	300	59.2

**表 5: K40 GPU 上的时间（ms）**，除了 SS 提议是在 CPU 上评估。“区域方面”包括 NMS，池化，全连接和 softmax 层。查看我们发布的代码来分析运行时间。

model	system	conv	proposal	region-wise	total	rate
VGG	SS + Fast R-CNN	146	1510	174	1830	0.5 fps
VGG	RPN + Fast R-CNN	141	10	47	198	5 fps
ZF	RPN + Fast R-CNN	31	3	25	59	17 fps

**RPN 上的消融实验。**为了研究 RPN 作为 proposal 方法的性能，我们进行了几项消融研究。首先，我们显示了 RPN 和 Fast R-CNN 检测网络共享卷积层的效果。为此，我们在四步训练过程的第二步之后停止训练。使用单独的网络将结果略微减少到 58.7%（RPN+ZF，非共享，表 2）。我们观察到，这是因为在第三步中，当使用检测器调整的特征来 fine-tune RPN 时，proposal 质量得到了改善。

接下来，我们分析 RPN 对训练 Fast R-CNN 检测网络的影响。为此，我们通过使用 2000 个 SS proposals 和 ZF 网络来训练 Fast R-CNN 模型。我们固定这个检测器，并通过改变测试时使用的 proposal regions 来评估检测的 mAP。在这些消融实验中，RPN 不与检测器共享特征。

在测试阶段用 300 个 RPN proposals 替换 SS proposals 得到了 56.8% 的 MAP。mAP 的下降是因为训练/测试 proposals 不一致。这个结果作为以下比较的基准。

有些令人惊讶的是，RPN 在测试时使用排名最高的 100 个 proposals 仍然会获得有竞争力的结果(55.1%)，表明排名靠前的 RPN proposals 是准确的。相反的，使用排名靠前的 6000 个 RPN proposals（没有进行 NMS）具有相当的 mAP（55.2%），这表明 NMS 不会损害检测 mAP 并可能减少误报。

接下来，我们通过测试时分别关闭 RPN 的 cls 和 reg 输出来研究 RPN 的作用。当 cls 层在测试时被移除（因此不使用 NMS/排名），我们从没有计分的区域中随机采样 N 个 proposals。当 N=1000(55.8%) 时，mAP 几乎没有变化，但是当 N=100 时，会大幅降低到 44.6%。这表明 cls 分数考虑了排名最高的 proposals 的准确性。

另一方面，当在测试阶段移除 reg 层（所以 proposals 变成 anchor 框）时，mAP 将下降到 52.1%。这表明高质量的 proposals 主要是由于回归的边界框。anchor 框虽然具有多个尺度和长宽比，但不足以进行准确的检测。

我们还单独评估了更强大的网络对 RPN proposal 质量的影响。我们使用 VGG-16 来训练 RPN，仍然使用上述的 SS+ZF 检测器。mAP 从 56.8%（使用 RPN+ZF）提高到 59.2%（使用 RPN+VGG）。这是一个很有希望的结果，因为这表明 RPN+VGG 的 proposal 质量要好于 RPN+ZF。由于 RPN+ZF 的 proposal 与 SS 具有竞争性（当一致用于训练和测试时，都是 58.7%），所以我们可以预期 RPN+VGG 比 SS 更好。以下实验验证了这个假设。

**VGG-16 的性能。**表 3 显示了 VGG-16 的 proposal 和检测结果。使用 RPN+VGG，非共享特征的结果是 68.5%，略高于 SS 基准模型。如上所示，这是因为 RPN+VGG 生成的 proposal 比 SS 更准确。与预先定义的 SS 不同，RPN 是主动训练的并从更好的网络中受益。对于特性共享的变种，结果是 69.9%——比强壮的 SS 基准模型更好，但几乎是零成本的 proposal。我们在 PASCAL VOC 2007 和 2012 的训



训练评估数据集上进一步训练 RPN 和检测网络。该 mAP 是 73.2%。图 5 显示了 PASCAL VOC 2007 测试集的一些结果。在 PASCAL VOC 2012 测试集（表 4）中，我们的方法在 VOC 2007 的 trainval+test 和 VOC 2012 的 trainval 的联合数据集上训练的模型取得了 70.4% 的 mAP。表 6 和表 7 所示为详细的数字。

表 3: PASCAL VOC 2007 测试集的检测结果。检测器是 Fast R-CNN 和 VGG-16。训练数据: “07”代表 VOC 2007 trainval, “07 + 12”代表 VOC 2007 trainval 和 VOC 2012 trainval 的联合训练集。对于 RPN, 训练时 Fast R-CNN 的 proposals 数量为 2000。†: [2]中报道的数字; 使用本文提供的仓库代码, 这个结果更高 (68.1)。

method	# proposals	data	mAP (%)
SS	2000	07	66.9 <sup>†</sup>
SS	2000	07+12	70.0
RPN+VGG, unshared	300	07	68.5
RPN+VGG, shared	300	07	69.9
RPN+VGG, shared	300	07+12	73.2
RPN+VGG, shared	300	COCO+07+12	78.8

表 4: PASCAL VOC 2012 测试集的检测结果。检测器是 Fast R-CNN 和 VGG-16。训练数据: “07”代表 VOC 2007 trainval, “07 + 12”代表 VOC 2007 trainval 和 VOC 2012 trainval 的联合训练集。对于 RPN, 训练时 Fast R-CNN 的提议数量为 2000。†: <http://host.robots.ox.ac.uk:8080/anonymous/HZJTQA.html>。‡: <http://host.robots.ox.ac.uk:8080/anonymous/YNPLXB.html>。§: <http://host.robots.ox.ac.uk:8080/anonymous/XEDH10.html>。

method	# proposals	data	mAP (%)
SS	2000	12	65.7
SS	2000	07++12	68.4
RPN+VGG, shared <sup>†</sup>	300	12	67.0
RPN+VGG, shared <sup>‡</sup>	300	07++12	70.4
RPN+VGG, shared <sup>§</sup>	300	COCO+07++12	75.9

表 6: 使用 Fast R-CNN 检测器和 VGG-16 在 PASCAL VOC 2007 测试集上的结果。对于 RPN, 训练时 Fast R-CNN 的提议数量为 2000。RPN\*表示没有共享特征版本。

method	# box	data	mAP	areo	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
SS	2000	07	66.9	74.5	78.3	69.2	53.2	36.6	77.3	78.2	82.0	40.7	72.7	67.9	79.6	79.2	73.0	69.0	30.1	65.4	70.2	75.8	65.8
SS	2000	07+12	70.0	77.0	78.1	69.3	59.4	38.3	81.6	78.6	86.7	42.8	78.8	68.9	84.7	82.0	76.6	69.9	31.8	70.1	74.8	80.4	70.4
RPN*	300	07	68.5	74.1	77.2	67.7	53.9	51.0	75.1	79.2	78.9	50.7	78.0	61.1	79.1	81.9	72.2	75.9	37.2	71.4	62.5	77.4	66.4
RPN	300	07	69.9	70.0	80.6	70.1	57.3	49.9	78.2	80.4	82.0	52.2	75.3	67.2	80.3	79.8	75.0	76.3	39.1	68.3	67.3	81.1	67.6
RPN	300	07+12	73.2	76.5	79.0	70.9	65.5	52.1	83.1	84.7	86.4	52.0	81.9	65.7	84.8	84.6	77.5	76.7	38.8	73.6	73.9	83.0	72.6
RPN	300	COCO+07+12	<u>78.8</u>	<u>84.3</u>	<u>82.0</u>	<u>77.7</u>	<u>68.9</u>	<u>65.7</u>	<u>88.1</u>	<u>88.4</u>	<u>88.9</u>	<u>63.6</u>	<u>86.3</u>	<u>70.8</u>	<u>85.9</u>	<u>87.6</u>	<u>80.1</u>	<u>82.3</u>	<u>53.6</u>	<u>80.4</u>	<u>75.8</u>	<u>86.6</u>	<u>78.9</u>

**表 7: 使用 Fast R-CNN 检测器和 VGG-16 在 PASCAL VOC 2012 测试集上的结果。对于 RPN，训练时 Fast R-CNN 的提议数量为 2000。**

method	# box	data	mAP	areo	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
SS	2000	12	65.7	80.3	74.7	66.9	46.9	37.7	73.9	68.6	87.7	41.7	71.1	51.1	86.0	77.8	79.8	69.8	32.1	65.5	63.8	76.4	61.7
SS	2000	07++12	68.4	82.3	78.4	70.8	52.3	38.7	77.8	71.6	89.3	44.2	73.0	55.0	87.5	80.5	80.8	72.0	35.1	68.3	<u>65.7</u>	80.4	64.2
RPN	300	12	67.0	82.3	76.4	71.0	48.4	45.2	72.1	72.3	87.3	42.2	73.7	50.0	86.8	78.7	78.4	77.4	34.5	70.1	57.1	77.1	58.9
RPN	300	07++12	70.4	84.9	79.8	74.3	53.9	49.8	77.5	75.9	88.5	45.6	77.1	55.3	86.9	81.7	80.9	79.6	40.1	72.6	60.9	81.2	61.5
RPN	300	COCO+07+++12	<u>75.9</u>	<u>87.4</u>	<u>83.6</u>	<u>76.8</u>	<u>62.9</u>	<u>59.6</u>	<u>81.9</u>	<u>82.0</u>	<u>91.3</u>	<u>54.9</u>	<u>82.6</u>	<u>59.0</u>	<u>89.0</u>	<u>85.5</u>	<u>84.7</u>	<u>84.1</u>	<u>52.2</u>	<u>78.9</u>	65.5	<u>85.4</u>	<u>70.2</u>

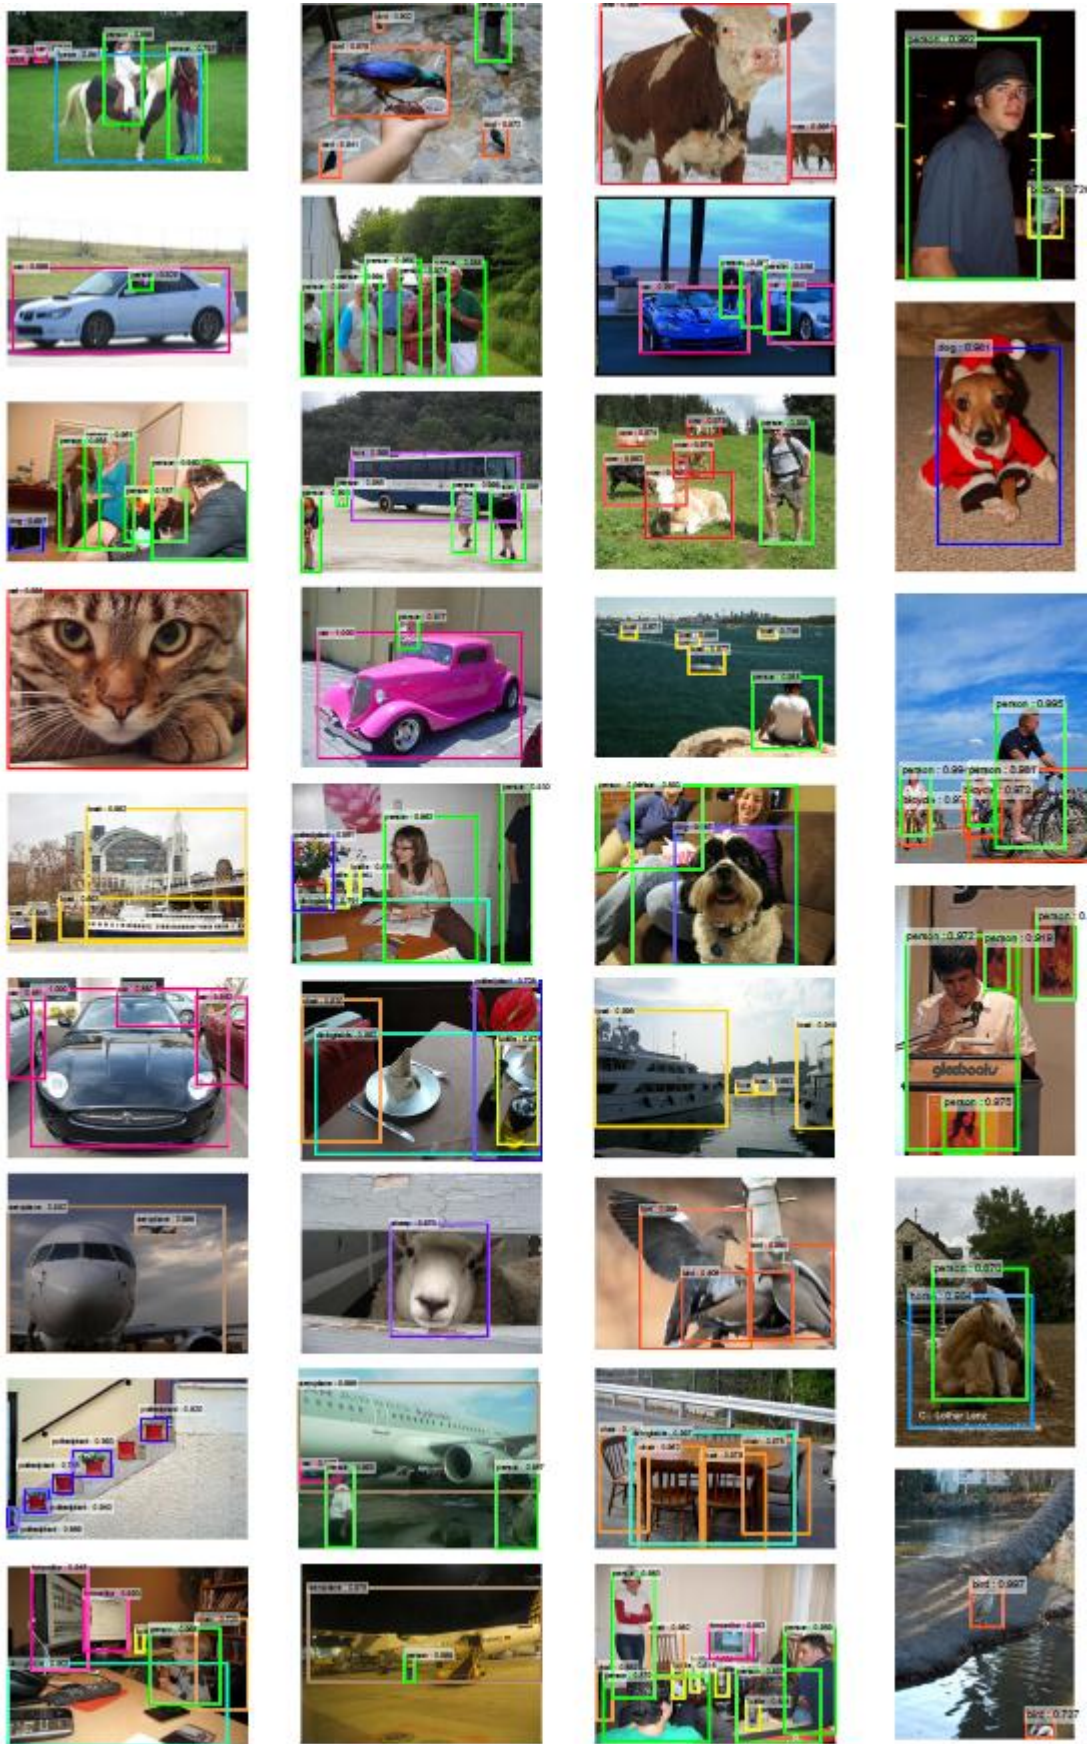


图 5: 使用 Faster R-CNN 系统在 PASCAL VOC 2007 测试集上目标检测结果的几个示例。该模型是 VGG-16, 训练数据是 07+12 trainval (2007 年测试集中 73.2% 的 mAP)。我们的方法检测广泛的尺度和长宽比目标。每个输出框都与类别标签和 [0, 1] 之间的 softmax 分数相关联。使用 0.6 的分数阈值来显示这些图像。获得这些结果包括所有步骤的运行时间为每张图像 198ms。

在表 5 中我们总结了整个目标检测系统的运行时间。根据内容 (平均大约 1.5s) SS 需要 1-2 秒, 而使用 VGG-16 的 Fast R-CNN 在 2000 个 SS proposals 上需要 320ms (如果在全连接层上使用 SVD[2], 则需要 223ms)。我们的 VGG-16 系统在 proposals 和检测上总共需要 198ms。在共享卷积特征的情况下, 单独 RPN 只需要 10ms 计算附加层。我们的区域计算也较低, 这要归功于较少的 proposals (每张图片 300 个)。我们的采用 ZF 网络的系统, 帧速率为 17fps。

**对超参数的敏感度。**在表 8 中, 我们研究了 anchor 的设置。默认情况下, 我们使用 3 个尺度和 3 个长宽比 (表 8 中 69.9% 的 mAP)。如果在每个位置只使用一个 anchor, 那么 mAP 的下降幅度将是 3-4%。如果使用 3 个尺度 (1 个长宽比) 或 3 个长宽比 (1 个尺度), 则 mAP 更高, 表明使用多种尺寸的 anchor 作为回归参考是有效的解决方案。在这个数据集上, 仅使用具有 1 个长宽比 (69.8%) 的 3 个尺度与使用具有 3 个长宽比的 3 个尺度一样好, 这表明尺度和长宽比不是检测准确度的解决维度。但我们仍然在设计中采用这两个维度来保持我们的系统灵活性。

在表 9 中, 我们比较了公式 (1) 中  $\lambda$  的不同值。默认情况下, 我们使用  $\lambda=10$ , 这使方程 (1) 中的两个项在归一化之后大致相等地加权。表 9 显示, 当  $\lambda$  在大约两个数量级 (1 到 100) 的范围内时,



我们的结果只是稍微受到影响（~1%）。这表明结果对宽范围内的  $\lambda$  不敏感。

**分析 IoU 召回率。**接下来，我们使用边界框真值来计算不同 IoU 比率的 proposals 召回率。值得注意的是，Recall-to-IoU 度量与最终的检测精度的基本不相关[19, 20, 21]。使用这个指标来诊断 proposals 方法比评估 proposals 方法更合适。

在图 4 中，我们显示了使用 300、1000 和 2000 个 proposals 的结果。我们与 SS 和 EB 进行比较，根据这些方法产生的置信度，取排名前 N 个 proposals 即为 N proposals。从图中可以看出，当 proposals 数量从 2000 个减少到 300 个时，RPN 方法表现优雅。这就解释了为什么 RPN 在使用 300 个 proposals 时具有良好的最终检测 mAP。正如我们之前分析过的，这个属性主要归因于 RPN 的 cls 项。当提议较少时，SS 和 EB 的召回率下降的比 RPN 更快。




图 4: PASCAL VOC 2007 测试集上的召回率和 IoU 重叠率。

**一阶段检测与两阶段 proposals + 检测。**OverFeat 论文[9]提出了一种在卷积特征图的滑动窗口上使用回归器和分类器的检测方法。OverFeat 是一个一阶段、类别特定的检测流程，而我们的是两阶段级联，包括类不可知的 proposals 和类别特定的检测。在 OverFeat 中，区域特征来自一个尺度金字塔上一个长宽比的滑动窗口。这些特征用

于同时确定目标的位置和类别。在 RPN 中，这些特征来自正方形 ( $3 \times 3$ ) 滑动窗口，并且预测相对于 anchor 具有不同尺度和长宽比的 proposals。虽然这两种方法都使用滑动窗口，但 region proposal 任务只是 Faster R-CNN 的第一阶段——下游的 Fast R-CNN 检测器会致力于对 proposals 进行细化。在我们级联的第二阶段，在更忠实覆盖区域特征的提议框中，区域特征自适应地聚集[1], [2]。我们相信这些功能会带来更准确的检测结果。

为了比较一阶段和两阶段系统，我们通过一阶段 Fast R-CNN 来模拟 OverFeat 系统（从而也规避了实现细节的其他差异）。在这个系统中，“proposals”是 3 个尺度（128、256、512）和 3 个长宽比（1:1, 1:2, 2:1）的密集滑动窗口。训练 Fast R-CNN 来预测类别特定的分数，并从这些滑动窗口中回归边界框位置。由于 OverFeat 系统采用图像金字塔，我们也使用从 5 个尺度中提取的卷积特征进行评估。我们使用[1], [2]中 5 个尺度。

表 10 比较了两阶段系统和一阶段系统的两个变种。使用 ZF 模型，一阶段系统具有 53.9% 的 mAP。这比两阶段系统(58.7%)低 4.8%。这个实验验证了级联 region proposal 和目标检测的有效性。在文献[2], [39]中报道了类似的观察结果，在这两篇论文中，用滑动窗取代 SS region proposal 会导致约 6% 的下降。我们也注意到，一阶段系统更慢，因为它产生了更多的 proposals。

**表 10：一阶段检测与两阶段 proposals + 检测。使用 ZF 模型和 Fast R-CNN 在 PASCAL VOC 2007 测试集上的检测结果。RPN 使用未共享的功能。**



	proposals		detector	mAP (%)
Two-Stage	RPN + ZF, unshared	300	Fast R-CNN + ZF, 1 scale	58.7
One-Stage	dense, 3 scales, 3 aspect ratios	20000	Fast R-CNN + ZF, 1 scale	53.8
One-Stage	dense, 3 scales, 3 aspect ratios	20000	Fast R-CNN + ZF, 5 scales	53.9

## 4.2 在 MS COCO 上的实验

我们呈现了在 Microsoft COCO 目标检测数据集[12]上很多的结果。这个数据集包含 80 个目标类别。我们用训练集上的 8 万张图像、验证集上的 4 万张图像以及测试开发集上的 2 万张图像进行实验。我们评估了  $\text{IoU} \in [0.5:0.05:0.95]$  的平均 mAP (COCO 标准度量, 简称为  $\text{mAP@[.5,.95]}$ ) 和  $\text{mAP}@0.5$  (PASCAL VOC 度量)。

我们的系统对这个数据集做了一些小的改动。我们在 8 个 GPU 上实现并训练了我们的模型, RPN (每个 GPU 1 个) 的有效小批量大小为 8, Fast R-CNN (每个 GPU 2 个) 为 16。RPN 和 Fast R-CNN 都进行了 24 万次迭代训练, 学习率为 0.003, 然后以 0.0003 的学习率进行 8 万次迭代。我们修改了学习率(从 0.003 而不是 0.001 开始), 因为小批量数据的大小发生了变化。对于 anchor, 我们使用 3 个长宽比和 4 个尺度 (加上  $64^2$ ), 这主要是通过处理这个数据集上的小目标来激发的。此外, 在我们的 Fast R-CNN 步骤中, 负样本定义为与实际边界框的最大 IOU 在  $[0, 0.5)$  区间内的样本, 而不是 [1], [2] 中使用的  $[0.1, 0.5)$  之间。我们注意到, 在 SPPnet 系统[1]中, 在  $[0.1, 0.5)$  中的负样本用于网络 fine-tune, 但  $[0, 0.5)$  中的负样本仍然在具有难例挖掘 SVM 步骤中被访问。但是 Fast R-CNN 系统[2]放弃了 SVM 步骤, 所以  $[0, 0.1]$  中的负样本都不会被访问。包括这些  $[0, 0.1]$  的样本, 在 Fast

R-CNN 和 Faster R-CNN 系统在 COCO 数据集上改进了  $mAP@0.5$  (但对 PASCAL VOC 的影响可以忽略不计)。

其余的实现细节与 PASCAL VOC 相同。特别的是，我们继续使用 300 个 proposals 和单一尺度 ( $s=600$ ) 测试。COCO 数据集上的测试时间仍然是大约 200ms 处理一张图像。

在表 11 中，我们首先报告了使用本文实现的 Fast R-CNN 系统[2]的结果。我们的 Fast R-CNN 基准模型在 test-dev 数据集上有 39.3% 的  $mAP@0.5$ ，比[2]中报告的更高。我们推测造成这种差距的原因主要是由于负样本的定义以及小批量大小的变化。我们也注意到  $mAP@[.5, .95]$  恰好相当。

**表 11: 在 MS COCO 数据集上的目标检测结果(%)。模型是 VGG-16。**

method	proposals	training data	COCO val		COCO test-dev	
			$mAP@.5$	$mAP@[.5, .95]$	$mAP@.5$	$mAP@[.5, .95]$
Fast R-CNN [2]	SS, 2000	COCO train	-	-	35.9	19.7
Fast R-CNN [impl. in this paper]	SS, 2000	COCO train	38.6	18.9	39.3	19.3
Faster R-CNN	RPN, 300	COCO train	41.5	21.2	42.1	21.5
Faster R-CNN	RPN, 300	COCO trainval	-	-	42.7	21.9

接下来我们评估了我们的 Faster R-CNN 系统。使用 COCO 训练集训练，在 COCO 测试开发集上 Faster R-CNN 有 42.1% 的  $mAP@0.5$  和 21.5% 的  $mAP@[0.5, 0.95]$ 。与相同配置下的 Fast R-CNN 相比， $mAP@0.5$  要高 2.8%， $mAP@[.5, .95]$  要高 2.2% (表 11)。这表明，在更高的 IoU 阈值上，RPN 对提高定位精度表现出色。使用 COCO 训练集训练，在 COCO 测试开发集上 Faster R-CNN 有 42.7% 的  $mAP@0.5$  和 21.9% 的  $mAP@[.5, .95]$ 。图 6 显示了 MS COCO 测试开发数据集中的一些结果。




图 6: 使用 Faster R-CNN 系统在 MS COCO test-dev 数据集上目标检测结果的一些示例。该模型是 VGG-16, 训练数据是 COCO 训练数据 (在测试开发数据集上为 42.7% 的 mAP@0.5)。每个输出框都与一个类别标签和 [0, 1] 之间的 softmax 分数相关联。使用 0.6 的分数阈值来显示这些图像。对于每张图像, 一种颜色表示该图像中的一个目标类别。

在 ILSVRC 和 COCO 2015 比赛中的 **Faster R-CNN**。我们已经证明，由于 RPN 通过神经网络完全学习了 propose regions，Faster R-CNN 从更好的特征中受益更多。即使将深度增加到 100 层以上，这种观察仍然是有效的[18]。仅用 101 层残差网络（ResNet-101）代替 VGG-16，Faster R-CNN 系统就将 mAP 从 41.5%/21.2%（VGG-16）增加到 48.4%/27.2%（ResNet-101）。与其他改进正交于 Faster R-CNN，何恺明等人[18]在 COCO 测试开发数据集上获得了单模型 55.7%/34.9% 的结果和 59.0%/37.4% 的组合结果，在 COCO 2015 目标检测竞赛中获得了第一名。同样的系统[18]也在 ILSVRC 2015 目标检测竞赛中获得了第一名，超过第二名绝对的 8.5%。RPN 也是 ILSVRC2015 定位和 COCO2015 分割竞赛第一名获奖输入的基石，详情请分别参见[18]和[15]。

### 4.3 从 MS COCO 到 PASCAL VOC

大规模数据对改善深度神经网络至关重要。接下来，我们研究了 MS COCO 数据集如何帮助改进在 PASCAL VOC 上的检测性能。

作为一个简单的基准模型，我们直接在 PASCAL VOC 数据集上评估 COCO 检测模型，而无需在任何 PASCAL VOC 数据上进行 fine-tune。这种评估是可行的，因为 COCO 类别是 PASCAL VOC 上类别的超集。在这个实验中忽略 COCO 专有的类别，softmax 层仅在 20 个类别和背景上执行。这种设置下 PASCAL VOC 2007 测试集上的 mAP 为 76.1%（表 12）。即使没有利用 PASCAL VOC 的数据，这个结果也好于在 VOC07+12(73.2%)上训练的模型的结果。



然后我们在 VOC 数据集上对 COCO 检测模型进行 fine-tune。在这个实验中，COCO 模型代替了 ImageNet 的预训练模型（用于初始化网络权重），Faster R-CNN 模型按 3.2 节所述进行 fine-tune。这样做在 PASCAL VOC 2007 测试集上可以达到 78.8% 的 mAP。来自 COCO 集合的额外数据增加了 5.6% 的 mAP。表 6 显示，在 PASCAL VOC 2007 上，使用 COCO+VOC 训练的模型在每个类别上具有最好的 AP 值。在 PASCAL VOC 2012 测试集（表 12 和表 7）中也观察到类似的改进。我们注意到获得这些强大结果的测试时间速度仍然是每张图像 200ms 左右。

表 12：使用不同的训练数据在 PASCAL VOC 2007 测试集和 2012 测试集上检测 Faster R-CNN 的检测 mAP（%）。模型是 VGG-16。“COCO”表示 COCO trainval 数据集用于训练。另见表 6 和表 7。

training data	2007 test	2012 test
VOC07	69.9	67.0
VOC07+12	73.2	-
VOC07++12	-	70.4
COCO (no VOC)	76.1	73.0
COCO+VOC07+12	78.8	-
COCO+VOC07++12	-	75.9

## 5. 结论

我们已经提出了 RPN 来生成高效、准确的 region proposal。通过与下游检测网络共享卷积特征，region proposal 步骤几乎是零成本的。我们的方法使统一的、基于深度学习的目标检测系统能够以接近实时的帧率运行。学习到的 RPN 也提高了 region proposal 的质量，从而提高了整体的目标检测精度。

## 参考文献

- [1] K. He, X. Zhang, S. Ren, and J. Sun, "Spatial pyramid pooling in deep convolutional networks for visual recognition," in European Conference on Computer Vision (ECCV), 2014.
- [2] R. Girshick, "Fast R-CNN," in IEEE International Conference on Computer Vision (ICCV), 2015.
- [3] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in International Conference on Learning Representations (ICLR), 2015.
- [4] J. R. Uijlings, K. E. van de Sande, T. Gevers, and A. W. Smeulders, "Selective search for object recognition," International Journal of Computer Vision (IJCV), 2013.
- [5] R. Girshick, J. Donahue, T. Darrell, and J. Malik, "Rich feature hierarchies for accurate object detection and semantic segmentation," in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2014.
- [6] C. L. Zitnick and P. Dollár, "Edge boxes: Locating object proposals from edges," in European Conference on Computer Vision (ECCV), 2014.
- [7] J. Long, E. Shelhamer, and T. Darrell, "Fully convolutional networks for semantic segmentation," in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015.
- [8] P. F. Felzenszwalb, R. B. Girshick, D. McAllester, and D. Ramanan, "Object detection with discriminatively trained part-based models," IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2010.
- [9] P. Sermanet, D. Eigen, X. Zhang, M. Mathieu, R. Fergus, and Y. LeCun, "Overfeat: Integrated recognition, localization and detection using convolutional networks," in International Conference on Learning Representations (ICLR), 2014.
- [10] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," in Neural Information Processing Systems (NIPS), 2015.
- [11] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, "The PASCAL Visual Object Classes Challenge 2007 (VOC2007) Results," 2007.
- [12] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: Common Objects in Context," in European Conference on Computer Vision (ECCV), 2014.
- [13] S. Song and J. Xiao, "Deep sliding shapes for amodal 3d object detection in rgb-d images," arXiv:1511.02300, 2015.
- [14] J. Zhu, X. Chen, and A. L. Yuille, "DeePM: A deep part-based model for object detection and semantic part localization," arXiv:1511.07131, 2015.
- [15] J. Dai, K. He, and J. Sun, "Instance-aware semantic segmentation via multi-task network cascades," arXiv:1512.04412, 2015.
- [16] J. Johnson, A. Karpathy, and L. Fei-Fei, "Densecap: Fully convolutional localization networks for dense captioning," arXiv:1511.07571, 2015.
- [17] D. Kislyuk, Y. Liu, D. Liu, E. Tzeng, and Y. Jing, "Human curation and convnets: Powering item-to-item recommendations on pinterest," arXiv:1511.04003, 2015.



- [18] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," arXiv:1512.03385, 2015.
- [19] J. Hosang, R. Benenson, and B. Schiele, "How good are detection proposals, really?" in British Machine Vision Conference (BMVC), 2014.
- [20] J. Hosang, R. Benenson, P. Dollar, and B. Schiele, "What makes for effective detection proposals?" IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2015.
- [21] N. Chavali, H. Agrawal, A. Mahendru, and D. Batra, "Object-Proposal Evaluation Protocol is 'Gameable'," arXiv: 1505.05836, 2015.
- [22] J. Carreira and C. Sminchisescu, "CPMC: Automatic object segmentation using constrained parametric min-cuts," IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2012.
- [23] P. Arbelaez, J. Pont-Tuset, J. T. Barron, F. Marques, and J. Malik, "Multiscale combinatorial grouping," in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2014.
- [24] B. Alexe, T. Deselaers, and V. Ferrari, "Measuring the objectness of image windows," IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2012.
- [25] C. Szegedy, A. Toshev, and D. Erhan, "Deep neural networks for object detection," in Neural Information Processing Systems (NIPS), 2013.
- [26] D. Erhan, C. Szegedy, A. Toshev, and D. Anguelov, "Scalable object detection using deep neural networks," in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2014.
- [27] C. Szegedy, S. Reed, D. Erhan, and D. Anguelov, "Scalable, high-quality object detection," arXiv:1412.1441 (v1), 2015.
- [28] P. O. Pinheiro, R. Collobert, and P. Dollar, "Learning to segment object candidates," in Neural Information Processing Systems (NIPS), 2015.
- [29] J. Dai, K. He, and J. Sun, "Convolutional feature masking for joint object and stuff segmentation," in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015.
- [30] S. Ren, K. He, R. Girshick, X. Zhang, and J. Sun, "Object detection networks on convolutional feature maps," arXiv:1504.06066, 2015.
- [31] J. K. Chorowski, D. Bahdanau, D. Serdyuk, K. Cho, and Y. Bengio, "Attention-based models for speech recognition," in Neural Information Processing Systems (NIPS), 2015.
- [32] M. D. Zeiler and R. Fergus, "Visualizing and understanding convolutional neural networks," in European Conference on Computer Vision (ECCV), 2014.
- [33] V. Nair and G. E. Hinton, "Rectified linear units improve restricted boltzmann machines," in International Conference on Machine Learning (ICML), 2010.
- [34] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, and A. Rabinovich, "Going deeper with convolutions," in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015.

- [35] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel, "Backpropagation applied to handwritten zip code recognition," *Neural computation*, 1989.
- [36] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei, "ImageNet Large Scale Visual Recognition Challenge," in *International Journal of Computer Vision (IJCV)*, 2015.
- [37] A. Krizhevsky, I. Sutskever, and G. Hinton, "Imagenet classification with deep convolutional neural networks," in *Neural Information Processing Systems (NIPS)*, 2012.
- [38] Y. Jia, E. Shelhamer, J. Donahue, S. Karayev, J. Long, R. Girshick, S. Guadarrama, and T. Darrell, "Caffe: Convolutional architecture for fast feature embedding," *arXiv:1408.5093*, 2014.
- [39] K. Lenc and A. Vedaldi, "R-CNN minus R," in *British Machine Vision Conference (BMVC)*, 2015.