

图像分类经典论文翻译汇总：[\[翻译汇总\]](#)

翻译 pdf 文件下载：[\[下载地址\]](#)

此版为纯中文版，中英文对照版请稳步：[\[GoogLeNet 纯中英文对照版\]](#)

# Going Deeper with Convolutions

## 走向更深的卷积神经网络

**Christian Szegedy**

Google Inc.

(谷歌)

**Wei Liu**

University of North Carolina, Chapel Hill

(北卡罗来纳大学教堂山分校)

**Yangqing Jia**

Google Inc.

(谷歌)

**Pierre Sermanet**

Google Inc.

**Scott Reed**

University of

Michigan

**Dragomir Anguelov**

Google Inc.

**Dumitru Erhan**

Google Inc.

(谷歌)

**Vincent Vanhoucke**

Google Inc.

(谷歌)

**Andrew Rabinovich**

Google Inc.

(谷歌)

### 摘要

我们在 ImageNet 大规模视觉识别挑战赛 2014 (ILSVRC14) 上提出了一种代号为 Inception 的深度卷积神经网络结构，并在分类和检测上取得了新的最好结果。这个架构的主要特点是提高了网络内部计算资源的利用率。通过精心的手工设计，我们在增加了网络深度和广度的同时保持了计算预算不变。为了优化质量，架构的设计以赫布理论和多尺度处理直觉为基础。我们在 ILSVRC14 提交中应用的一个特例被称为 GoogLeNet，一个 22 层的深度网络，其质量在分类和检测的背景下进行了评估。

### 1. 引言

过去三年中，由于深度学习和卷积网络的发展[10]，我们的目标分类和检测能力得到了显著提高。一个令人鼓舞的消息是，大部分的进步不仅仅是更强大硬件、更大数据集、更大模型的结果，而主要是新的想法、算法和网络结构改进的结果。例如，ILSVRC 2014 竞赛中最靠前的团队将分类的数据集用于相同竞赛的检测任务，没有使用新的数据资源。我们在 ILSVRC 2014 中的 GoogLeNet 提交实际使用的参数只有两年前 Krizhevsky 等人[9]获胜结构参数的 1/12，而结果明显更准确。在目标检测前沿，最大的收获不是来自于越来越大的深度网络的简单应用，而是来自于深度架构和经典计算机视觉的协同，像 Girshick 等人[6]的 R-CNN 算法那样。

另一个显著因素是随着移动和嵌入式设备的推动，我们的算法的效率很重要——尤其是在电力和内存使用上。值得注意的是，正是包含了这个因素的考虑才得出了本文中呈现的深度架构设计，而不是单纯的为了提高准确率。对于大多数实验来说，模型被设计为在一次推断中保持 15 亿乘加的计算预算，所以最终它们不是单纯的学术好奇心，而是能在现实世界中应用，甚至是以合理的代价在大型数据集上使用。

在本文中，我们将关注一个高效的计算机视觉深度神经网络架构，代号为 Inception，它的名字来自于 Lin 等人[12]网络论文中的 Network 与著名的“we need to go deeper”网络迷因[1]的结合。在我们的案例中，单词“deep”用在两个不同的含义中：首先，在某种意义上，我们以“Inception module”的形式引入了一种新层次的组织方式，在更直接的意义增加了网络的深度。一般来说，可以把 Inception 模型看作论文[12]的逻辑顶点同时从 Arora 等人[2]的理论工作中受到了鼓

舞和引导。这种架构的好处在 ILSVRC 2014 分类和检测挑战赛中通过实验得到了验证，它明显优于目前的最好水平。

## 2. 近期工作

从 LeNet-5 [10]开始，卷积神经网络（CNN）通常有一个标准结构——堆叠的卷积层（后面可以选择有对比归一化和最大池化）后面是一个或更多的全连接层。这个基本设计的变种在图像分类领域流行，并且目前为止在 MNIST, CIFAR 和更著名的 ImageNet 分类挑战赛中 [9, 21]的已经取得了最佳结果。对于更大的数据集例如 ImageNet 来说，最近的趋势是增加层的数目[12]和层的大小[21, 14]，同时使用 dropout[7]来解决过拟合问题。

尽管担心最大池化层会引起准确空间信息的损失，但与[9]相同的卷积网络结构也已经成功的应用于定位[9, 14]，目标检测[6, 14, 18, 5]和行人姿态估计[19]。

受灵长类视觉皮层神经科学模型的启发，Serre 等人[15]使用了一系列固定的不同大小的 Gabor 滤波器来处理多尺度。我们使用了一个类似的策略。然而，与[15]的固定的 2 层深度模型不同，Inception 结构中所有的滤波器是学习到的。此外，Inception 层重复了很多次，在 GoogLeNet 模型中得到了一个 22 层的深度模型。

Network-in-Network 是 Lin 等人[12]为了增加神经网络表现能力而提出的一种方法。在他们的模型中，网络中添加了额外的  $1 \times 1$  卷积层，增加了网络的深度。我们的架构中大量的使用了这个方法。但是，在我们的设置中， $1 \times 1$  卷积有两个目的：最关键的是，它们主要是用来作为降维模块来移除卷积瓶颈，否则将会限制我们网络的

大小。这不仅允许了深度的增加，而且允许我们网络的宽度增加但没有明显的性能损失。

目前最好的目标检测是 Girshick 等人[6]的基于区域的卷积神经网络（R-CNN）方法。R-CNN 将整个检测问题分解为两个子问题：利用低层次的信号例如颜色，纹理以跨类别的方式来产生目标位置候选区域，然后用 CNN 分类器来识别那些位置上的对象类别。这样一种两个阶段的方法利用了低层特征分割边界框的准确性，也利用了目前的 CNN 非常强大的分类能力。我们在我们的检测提交中采用了类似的方式，但探索增强这两个阶段，例如对于更高的目标边界框召回使用多盒[5]预测，并融合了更好的边界框候选区域分类方法。

### 3. 动机和高层思考

提高深度神经网络性能最直接的方式是增加它们的尺寸。这不仅包括增加深度——网络层次的数目——也包括它的宽度：每一层的单元数目。这是一种训练更高质量模型容易且安全的方法，尤其是在可获得大量标注的训练数据的情况下。但是这个简单方案有两个主要的缺点。

更大的尺寸通常意味着更多的参数，这会使增大的网络更容易过拟合，尤其是在训练集的标注样本有限的情况下。这是一个主要的瓶颈，因为要获得强标注数据集费时费力且代价昂贵，经常需要专家评委在各种细粒度的视觉类别进行区分，例如图 1 中显示的 ImageNet 中的类别（甚至是 1000 类 ILSVRC 的子集）。



(a) 西伯利亚哈士奇犬

(b) 爱斯基摩犬

**图 1:** ILSVRC 2014 分类挑战赛的 1000 类中两个不同的类别。区分这些类别需要领域知识。

均匀增加网络尺寸的另一个缺点是计算资源使用的显著增加。例如，在一个深度视觉网络中，如果两个卷积层相连，它们的滤波器数目的任何均匀增加都会引起计算量平方方式的增加。如果增加的容量使用效率低下（例如，如果大多数权重最终接近于 0），那么会浪费大量的计算能力。由于计算预算总是有限的，计算资源的有效分布更偏向于尺寸无差别的增加，即使主要目标是增加性能的质量。

解决这两个问题的一个基本的方式就是引入稀疏性并将全连接层替换为稀疏的全连接层，甚至是在卷积层内使用稀疏性。除了模仿生物系统之外，由于 Arora 等人[2]的开创性工作，这也具有更坚固的理论基础优势。他们的主要成果说明如果数据集的概率分布可以通过一个大型稀疏的深度神经网络表示，则最优的网络拓扑结构可以通过分析前一层激活的相关性统计和聚类高度相关的神经元来一层层的构建。虽然严格的数学证明需要在很强的条件下，但事实上这个声明与著名的赫布理论产生共鸣——神经元一起激发，一起连接——实践表明，基础概念甚至适用于不严格的条件下。

遗憾的是，当碰到在非均匀的稀疏数据结构上进行数值计算时，现在的计算架构效率非常低下。即使算法运算的数量减少 100 倍，查询和缓存丢失上的开销仍占主导地位：切换到稀疏矩阵可能是不可行的。随着稳定提升和高度调整的数值库的应用，差距仍在进一步扩大，数值库要求极度快速密集的矩阵乘法，利用底层的 CPU 或 GPU 硬件 [16, 9] 的微小细节。非均匀的稀疏模型也要求更多的复杂工程和计算基础结构。目前大多数面向视觉的机器学习系统通过采用卷积的优点来利用空域的稀疏性。然而，卷积被实现为对上一层块的密集连接的集合。为了打破对称性，提高学习水平，从论文 [11] 开始，ConvNets 习惯上在特征维度使用随机的稀疏连接表，然而为了进一步优化并行计算，论文 [9] 中趋向于变回全连接。目前最新的计算机视觉架构有统一的结构。更多的滤波器和更大的批大小要求密集计算的有效使用。

这提出了下一个中间步骤是否有希望的问题：一个架构能利用滤波器水平的稀疏性，正如理论所认为的那样，但能通过利用密集矩阵计算来利用我们目前的硬件。稀疏矩阵乘法的大量文献（例如 [3]）认为对于稀疏矩阵乘法，将稀疏矩阵聚类为相对密集的子矩阵会有更佳的性能。在不久的将来会利用类似的方法来进行非均匀深度学习架构的自动构建，这样的想法似乎并不牵强。

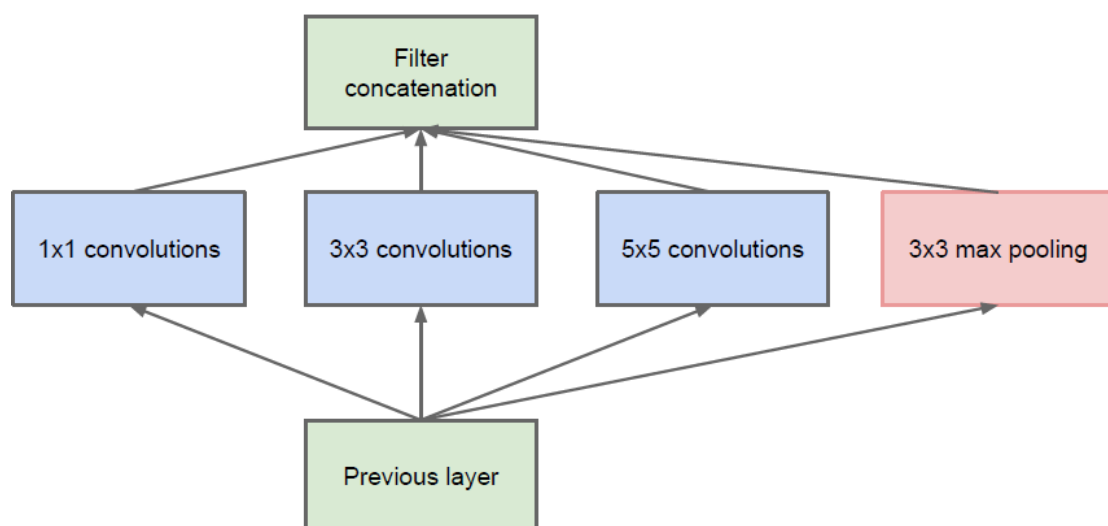
Inception 架构开始是作为案例研究，用于评估一个复杂网络拓构建算法的假设输出，该算法试图近似 [2] 中所示的视觉网络的稀疏结构，并通过密集的、容易获得的组件来覆盖假设结果。尽管是一个非常投机的事情，但与基于 [12] 的参考网络相比，早期可以观测到适度的收益。随着一点点调整加宽差距，作为 [6] 和 [5] 的基础网络，Inception 被证明在定位上下文和目标检测中尤其有用。有趣的是，虽



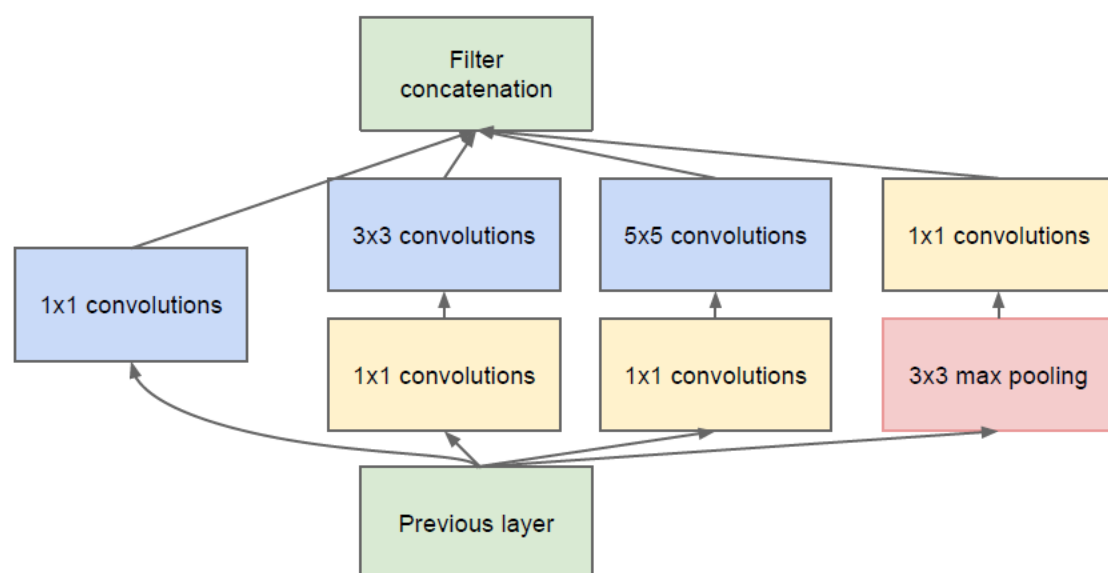
然大多数最初的架构选择已被质疑并分离开进行全面测试，但结果证明它们是局部最优的。然而必须谨慎：尽管 Inception 架构在计算机上领域取得成功，但这是否可以归因于构建其架构的指导原则仍是有疑问的。确保这一点将需要更彻底的分析 and 验证。

#### 4. 架构细节

Inception 架构的主要想法是考虑怎样近似卷积视觉网络的最优稀疏结构并用容易获得的密集组件进行覆盖。注意假设转换不变性，这意味着我们的网络将以卷积构建块为基础。我们所需要做的是找到最优的局部构造并在空间上重复它。Arora 等人[2]提出了一个层次结构，其中应该分析最后一层的相关统计并将它们聚集成具有高相关性的单元组。这些聚类形成了下一层的单元并与前一层的单元连接。我们假设较早层的每个单元都对应输入层的某些区域，并且这些单元被分成滤波器组。在较低的层（接近输入的层）相关单元集中在局部区域。因此，如[12]所示，我们最终会有许多聚类集中在单个区域，它们可以通过下一层的  $1 \times 1$  卷积层覆盖。然而也可以预期，将存在更小数目的在更大空间上扩展的聚类，其可以被更大块上的卷积覆盖，这将在越来越大的区域上块的数量将会下降。为了避免块校正的问题，目前 Inception 架构形式的滤波器的尺寸仅限于  $1 \times 1$ 、 $3 \times 3$ 、 $5 \times 5$ ，这样做更多的是基于其便易性而非必需。这也意味着提出的架构是所有这些层的组合，其输出滤波器组连接成单个输出向量形成了下一阶段的输入。另外，由于池化操作对于目前卷积网络的成功至关重要，因此建议在每个这样的阶段添加一个替代的并行池化路径应该具有额外的有益效果（看图 2(a)）。



(a) Inception 模块，naïve 版



(b) 降维的 Inception 模块

图 2: Inception 模块

由于这些“Inception 模块”在**每个模型**的顶部堆叠，其输出相关性统计必然有变化：由于较高层会捕获较高的抽象特征，其空间集中度预计会减少。这表明随着转移到更高层， $3\times 3$  和  $5\times 5$  卷积的比例应该会增加。

上述模块的一个大问题是在具有大量滤波器的卷积层之上，即使适量的  $5\times 5$  卷积也可能是非常昂贵的，至少在这种 **naïve 版本**中有



这个问题。一旦池化单元添加到混合中，这个问题甚至会变得更明显：输出滤波器的数量等于前一阶段滤波器的数量。池化层输出和卷积层输出的合并会导致这一阶段到下一阶段输出数量不可避免的增加。虽然这种架构可能会覆盖最优稀疏结构，但它会非常低效，导致在几个阶段内计算量爆炸。

这导致了 Inception 架构的第二个想法：在计算要求会增加太多的地方，明智地减少维度。这是基于嵌入的成功：甚至低维嵌入可能包含大量关于较大图像块的信息。嵌入以密集、压缩的形式表示信息，**然而**压缩信息更难处理。这种表示应该在大多数地方保持稀疏（根据 [2] 中条件的要求）并且仅在它们必须汇总时才压缩信号。也就是说，在昂贵的  $3 \times 3$  和  $5 \times 5$  卷积之前， $1 \times 1$  卷积用来计算降维。除了用来降维之外，它们的第二个作用是使用线性修正单元。最终的结果如图 2(b) 所示。

通常，Inception 网络是一个由上述类型的模块互相堆叠组成的网络，偶尔会有步长为 2 的最大池化层将网络分辨率减半。出于技术原因（训练过程中内存效率），只在更高层开始使用 Inception 模块而在更低层仍保持传统的卷积形式似乎是有益的。这不是绝对必要的，只是反映了我们目前实现中的一些基础结构效率低下。

该架构的一个有用的方面是它允许显著增加每个阶段的单元数量，而不会在后面的阶段出现计算复杂度不受控制的爆炸。这是在尺寸较大的块进行昂贵的卷积之前通过普遍使用降维实现的。此外，设计遵循了实践直觉，即视觉信息应该在不同的尺度上处理然后聚合，为的是下一阶段可以从不同尺度同时抽象特征。

计算资源的改善使用允许增加每个阶段的宽度和阶段的数量，而不会陷入计算困境。可以利用 Inception 架构创建略差一些但计算成本更低的版本。我们发现所有可用的控制允许计算资源的受控平衡，导致网络比没有 Inception 结构的类似执行网络快 3—10 倍，但是在这一点上需要仔细的手动设计。

## 5. GoogLeNet

通过“GoogLeNet”这个名字，我们提到了在 ILSVRC 2014 竞赛的提交中使用的 Inception 架构的特例。我们也使用了一个稍微优质的更深更宽的 Inception 网络，但将其加入到组合中似乎只稍微提高了结果。我们忽略了该网络的细节，因为经验证据表明确切架构的参数影响相对较小。表 1 说明了竞赛中使用的最常见的 Inception 实例。这个网络（用不同的图像块采样方法训练的）使用了我们组合中 7 个模型中的 6 个。

type	patch size/ stride	output size	depth	# 1×1	# 3×3 reduce	# 3×3	# 5×5 reduce	# 5×5	pool proj	params	ops
convolution	7×7/2	112×112×64	1							2.7K	34M
max pool	3×3/2	56×56×64	0								
convolution	3×3/1	56×56×192	2		64	192				112K	360M
max pool	3×3/2	28×28×192	0								
inception (3a)		28×28×256	2	64	96	128	16	32	32	159K	128M
inception (3b)		28×28×480	2	128	128	192	32	96	64	380K	304M
max pool	3×3/2	14×14×480	0								
inception (4a)		14×14×512	2	192	96	208	16	48	64	364K	73M
inception (4b)		14×14×512	2	160	112	224	24	64	64	437K	88M
inception (4c)		14×14×512	2	128	128	256	24	64	64	463K	100M
inception (4d)		14×14×528	2	112	144	288	32	64	64	580K	119M
inception (4e)		14×14×832	2	256	160	320	32	128	128	840K	170M
max pool	3×3/2	7×7×832	0								
inception (5a)		7×7×832	2	256	160	320	32	128	128	1072K	54M
inception (5b)		7×7×1024	2	384	192	384	48	128	128	1388K	71M
avg pool	7×7/1	1×1×1024	0								
dropout (40%)		1×1×1024	0								
linear		1×1×1000	1							1000K	1M
softmax		1×1×1000	0								

表 1: Inception 架构的 GoogLeNet

所有的卷积都使用了修正线性激活，包括 Inception 模块内部的卷积。在我们的网络中感受野是在均值为 0 的 RGB 颜色空间中，大

小是  $224 \times 224$ 。“ $\#3 \times 3$  reduce”和“ $\#5 \times 5$  reduce”表示在  $3 \times 3$  和  $5 \times 5$  卷积之前，降维层使用的  $1 \times 1$  滤波器的数量。在 pool proj 列可以看到内置的最大池化之后，投影层中  $1 \times 1$  滤波器的数量。所有的这些降维/投影层也都使用了线性修正激活。

网络的设计考虑了计算效率和实用性，以便可以在单独的设备上运行，甚至包括那些计算资源有限的设备，尤其是低内存占用的设备。当只计算有参数的层时，网络有 22 层（如果我们也计算池化层是 27 层）。构建网络的全部层（独立构建块）的数目大约是 100。确切的数量取决于机器学习基础架构对层的计算方式。分类器之前的平均池化是基于[12]的，尽管我们的实现有一个额外的线性层。这个线性层使我们的网络能很容易地适应其它的标签集，但它主要是为了方便使用，我们不期望它有重大的影响。我们发现从全连接层变为平均池化，提高了大约 top-1 %0.6 的准确率，然而即使在移除了全连接层之后，dropout 的使用还是必不可少的。

对于一个相对较深的网络，如何将梯度有效地反向传播到所有层是个问题。在这个任务上，更浅网络的强大性能表明网络中部层产生的特征应该是非常有识别力的。通过将辅助分类器添加到这些中间层，可以期望较低阶段分类器具有更好的判别力。这被认为是在提供正则化的同时克服梯度消失问题。这些分类器采用较小卷积网络的形式，放置在 Inception (4a)和 Inception (4b)模块的输出之上。在训练期间，它们的损失以折扣权重（辅助分类器损失的权重是 0.3）加到网络的整个损失上。在推断时，这些辅助网络被丢弃。后面的对照实验表明辅助网络的影响相对较小（约 0.5），只需要其中一个就能取得同样的效果。

包括辅助分类器在内的附加网络的具体结构如下：

- 一个滤波器大小  $5 \times 5$ ，步长为 3 的平均池化层，(4a)阶段结果输出为  $4 \times 4 \times 512$ ，(4d)阶段结果输出为  $4 \times 4 \times 528$ 。
- 具有 128 个滤波器的  $1 \times 1$  卷积，用于降维和修正线性激活。
- 一个具有 1024 个单元和修正线性激活的全连接层，。
- 丢弃率为 70% 的 dropout 层。
- 使用带有 softmax 损失的线性层作为分类器（作为主分类器预测同样的 1000 类，但在推断时移除）。

最终的神经网络模型图如图 3 所示。



图 3：含有的所有结构的 GoogLeNet 网络

## 6. 训练方法

GoogLeNet 网络使用 DistBelief[4]分布式机器学习系统进行训练，该系统使用适量的模型和数据并行化。尽管我们仅使用一个基于 CPU 的实现，但粗略的估计表明 GoogLeNet 网络可以用更少的高端 GPU

在一周之内训练到收敛，主要的限制是内存使用。我们的训练使用异步随机梯度下降，动量参数为 0.9[17]，固定的学习率计划（每 8 次遍历下降学习率 4%）。Polyak 平均[13]在推断时用来创建最终的模型。

图像采样方法在过去几个月的竞赛中发生了重大变化，并且已收敛的模型在其他选项上进行了训练，有时还结合着超参数的改变，例如 dropout 和学习率。因此，很难对训练这些网络的最有效的单一方式给出一个明确指导。让事情更复杂的是，受[8]的启发，一些模型主要是在相对较小的裁剪图像进行训练，其它模型主要是在相对较大的裁剪图像上进行训练。然而，一个经过验证的方案在竞赛后工作地很好，包括各种尺寸的图像块的采样，它的尺寸均匀分布在图像区域的 8%-100% 之间，方向角限制为  $[34, 43]$  之间。另外，我们发现 Andrew Howard[8]的光度扭曲对于克服训练数据成像条件的过拟合是有用的。

利用分布式机器学习系统和数据并行来训练网络，虽然实现时只用了 CPU，但是是可以用品个别高端的 GPU 一周达到收敛的。采用异步随机梯度下降，动量为 0.9，学习率每 8 个 epoch 下降 4%。用 Polyak 平均来创建最后的模型。图像采样的 patch 大小从图像的 8% 到 100%，选取的长宽比在  $3/4$  到  $4/3$  之间，光度扭曲也有利于减少过拟合，还使用随机插值方法结合其他超参数的改变来调整图像大小。

## 7. ILSVRC 2014 分类挑战赛设置和结果

ILSVRC 2014 分类挑战赛包括将图像分类到 ImageNet 层级中 1000 个叶子结点类别的任务。训练图像大约有 120 万张，验证图像有 5 万张，测试图像有 10 万张。每一张图像与一个实际类别相关联，性能度量基于分类器预测的最高分。通常报告两个数字：top-1 准确



率，比较实际类别和第一个预测类别，top-5 错误率，比较实际类别与前 5 个预测类别：如果图像实际类别在 top-5 中，则认为图像分类正确，不管它在 top-5 中的排名。挑战赛使用 top-5 错误率来进行排名。

我们参加竞赛时没有使用额外的数据来训练。除了本文中前面提到的训练技术之外，我们在测试时为了获得更高性能采用了一系列技巧，描述如下。

1. 我们独立训练了 7 个版本的类似的 GoogLeNet 模型（包括一个更广泛的版本），并用它们进行了整体预测。这些模型的训练具有相同的初始化（甚至具有相同的初始权重，由于监督）和学习率策略。它们仅在采样方法和随机输入图像顺序方面不同。

2. 在测试中，我们采用比 Krizhevsky 等人[9]更激进的裁剪方法。具体来说，我们将图像归一化为四个尺度，其中较短维度（高度或宽度）分别为 256，288，320 和 352，取这些归一化的图像的左，中，右方块（在肖像图片中，我们采用顶部，中心和底部方块）。对于每个方块，我们将采用 4 个角以及中心  $224 \times 224$  裁剪图像以及方块尺寸归一化为  $224 \times 224$ ，以及它们的镜像版本。这导致每张图像会得到  $4 \times 3 \times 6 \times 2 = 144$  的裁剪图像。前一年的参赛的 Andrew Howard[8]采用了类似的方法，经过我们实证验证，其方法略差于我们提出的方案。我们注意到，在实际应用中，这种激进裁剪可能是不必要的，因为存在合理数量的裁剪图像后，更多裁剪图像的好处会变得很微小（正如我们后面展示的那样）。

3. softmax 概率在多个裁剪图像上和所有单个分类器上进行平均，然后获得最终预测。在我们的实验中，我们分析了验证数据的替代方



法，例如裁剪图像上的最大池化和分类器的平均，但是它们比简单平均的性能略逊。

在本文的其余部分，我们分析了有助于最终提交整体性能的多个因素。

竞赛中我们的最终提交在验证集和测试集上得到了 top-5 6.67% 的错误率，在其它的参与者中排名第一。与 2012 年的 SuperVision 方法相比相对减少了 56.5%，与前一年的最佳方法（Clarifai）相比相对减少了约 40%，这两种方法都使用了外部数据训练分类器。表 2 显示了过去三年中一些表现最好的方法的统计。

Team	Year	Place	Error (top-5)	Uses external data
SuperVision	2012	1st	16.4%	no
SuperVision	2012	1st	15.3%	Imagenet 22k
Clarifai	2013	1st	11.7%	no
Clarifai	2013	1st	11.2%	Imagenet 22k
MSRA	2014	3rd	7.35%	no
VGG	2014	2nd	7.32%	no
GoogLeNet	2014	1st	6.67%	no

表 2：分类性能

我们也分析报告了多种测试选择的性能，当预测图像时通过改变表 3 中使用的模型数目和裁剪图像数目。当我们使用一个模型时，我们选择了在验证数据上 top-1 错误率最低的模型。报告验证数据集上的所有数据，以便不会在测试数据上过度拟合。

Number of models	Number of Crops	Cost	Top-5 error	compared to base
1	1	1	10.07%	base
1	10	10	9.15%	-0.92%
1	144	144	7.89%	-2.18%
7	1	7	8.09%	-1.98%
7	10	70	7.62%	-2.45%
7	144	1008	6.67%	-3.45%

表 3: GoogLeNet 分类性能分解

## 8. ILSVRC 2014 检测挑战赛设置和结果

ILSVRC 检测任务是为了在 200 个可能的类别中生成图像中目标的边界框。如果检测到的对象匹配的它们实际类别并且它们的边界框重叠至少 50%（使用 Jaccard 索引），则将检测到的对象记为正确。无关的检测记为假阳性且被惩罚。与分类任务不同，每张图像可能包含多个对象或没有对象，并且它们的尺度可能是多变的。报告的结果使用平均精度均值（mAP）。

GoogLeNet 检测采用的方法类似于 R-CNN[6]，但用 Inception 模块作为区域分类器进行了增强。此外，为了更高的目标边界框召回率，通过选择搜索[20]方法和多箱[5]预测相结合改进了区域生成步骤。为了减少假阳性的数量，超分辨率的尺寸增加了 2 倍。这将选择搜索算法的区域生成减少了一半。我们总共补充了 200 个来自多盒结果的区域生成，大约 60%的区域生成用于[6]，同时将覆盖率从 92%提高到 93%。减少区域生成的数量，增加覆盖率的整体影响是对于单个模型的情况平均精度均值增加了 1%。最后，等分类单个区域时，我们使用了 6 个 GoogLeNets 的组合。这使得准确率从 40%提高到 43.9%。注意，与 R-CNN 相反，由于缺少时间我们没有使用边界框回归。

我们首先报告了最好检测结果，并显示了从第一版检测任务以来的进展。与 2013 年的结果相比，准确率几乎翻了一倍。所有表现最

好的团队都使用了卷积网络。我们在表 4 中报告了官方的分数和每个队伍的常见策略：使用外部数据、集成模型或上下文模型。外部数据通常是 ILSVRC12 的分类数据，用来预训练模型，后面在检测数据集上进行改善。一些团队也提到使用了定位数据。由于定位任务的边界框很大一部分不在检测数据集中，所以可以用该数据预训练一般的边界框回归器，这与分类预训练的方式相同。GoogLeNet 团队没有使用定位数据进行预训练。

Team	Year	Place	mAP	external data	ensemble	approach
UvA-EuVision	2013	1st	22.6%	none	?	Fisher vectors
Deep Insight	2014	3rd	40.5%	ImageNet 1k	3	CNN
CUHK DeepID-Net	2014	2nd	40.7%	ImageNet 1k	?	CNN
GoogLeNet	2014	1st	43.9%	ImageNet 1k	6	CNN

表 4：检测性能

在表 5 中，我们仅比较了单个模型的结果。最好性能模型是 Deep Insight 的，令人惊讶的是 3 个模型的集合仅提高了 0.3 个点，而 GoogLeNet 在模型集成时明显获得了更好的结果。

Team	mAP	Contextual model	Bounding box regression
Trimps-Sousheh	31.6%	no	?
Berkeley Vision	34.5%	no	yes
UvA-EuVision	35.4%	?	?
CUHK DeepID-Net2	37.7%	no	?
GoogLeNet	38.02%	no	no
Deep Insight	40.2%	yes	yes

表 5：单个模型的检测性能

## 9. 结论

我们的结果取得了可靠的证据，即通过易获得的密集构造块来近似期望的最优稀疏结果是改善计算机视觉神经网络的一种可行方法。相比于较浅且较窄的架构，这个方法的主要优势是在计算需求适度增加的情况下有显著的质量收益。

同时，需要注意的是我们的目标检测工作虽然没有利用上下文，也没有执行边界框回归，但仍然具有竞争力，这进一步显示了 Inception 架构优势的证据。

对于分类和检测，预期通过更昂贵的类似深度和宽度的非 Inception 类型网络可以实现类似质量的结果。然而，我们的方法取得了可靠的证据，即转向更稀疏的结构一般来说是可行有用的想法。这表明未来的工作将在[2]的基础上以自动化方式创建更稀疏更精细的结构，以及将 Inception 架构的思考应用到其他领域。

## 10. 致谢

我们要感谢 Sanjeev Arora 和 Aditya Bhaskara 就[2]进行了富有成果的讨论。此外，我们感谢 DistBelief [4]团队的支持，尤其是 Rajat Monga, Jon Shlens, Alex Krizhevsky, Jeff Dean, Ilya Sutskever 和 Andrea Frome。我们还要感谢 Tom Duerig 和 Ning Ye 对光度失真方面的帮助。如果没有 Chuck Rosenberg 和 Hartwig Adam 的支持，我们的工作也是不可能完成的。

## 参考文献

- [1] Know your meme: We need to go deeper. <http://knowyourmeme.com/memes/we-need-to-go-deeper>. Accessed: 2014-09-15.
- [2] S. Arora, A. Bhaskara, R. Ge, and T. Ma. Provable bounds for learning some deep representations. CoRR, abs/1310.6343, 2013.
- [3] U. V. Catalyurek, C. Aykanat, and B. Ucar. On two-dimensional sparse matrix partitioning: Models, methods, and a recipe. SIAM J. Sci. Comput., 32(2):656 – 683, Feb. 2010.
- [4] J. Dean, G. Corrado, R. Monga, K. Chen, M. Devin, M. Mao, M. Ranzato, A. Senior, P. Tucker, K. Yang, Q. V. Le, and A. Y. Ng. Large scale distributed deep networks. In P. Bartlett, F. Pereira, C. Burges, L. Bottou, and K. Weinberger, editors, NIPS, pages 1232 – 1240. 2012.

- [5] D. Erhan, C. Szegedy, A. Toshev, and D. Anguelov. Scalable object detection using deep neural networks. In CVPR, 2014.
- [6] R. B. Girshick, J. Donahue, T. Darrell, and J. Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In Computer Vision and Pattern Recognition, 2014. CVPR 2014. IEEE Conference on, 2014.
- [7] G. E. Hinton, N. Srivastava, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov. Improving neural networks by preventing co-adaptation of feature detectors. CoRR, abs/1207.0580, 2012.
- [8] A. G. Howard. Some improvements on deep convolutional neural network based image classification. CoRR, abs/1312.5402, 2013.
- [9] A. Krizhevsky, I. Sutskever, and G. Hinton. Imagenet classification with deep convolutional neural networks. In Advances in Neural Information Processing Systems 25, pages 1106 – 1114, 2012.
- [10] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel. Backpropagation applied to handwritten zip code recognition. Neural Comput., 1(4):541 – 551, Dec. 1989.
- [11] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11):2278 – 2324, 1998.
- [12] M. Lin, Q. Chen, and S. Yan. Network in network. CoRR, abs/1312.4400, 2013.
- [13] B. T. Polyak and A. B. Juditsky. Acceleration of stochastic approximation by averaging. SIAM J. Control Optim., 30(4):838 – 855, July 1992.
- [14] P. Sermanet, D. Eigen, X. Zhang, M. Mathieu, R. Fergus, and Y. LeCun. Overfeat: Integrated recognition, localization and detection using convolutional networks. CoRR, abs/1312.6229, 2013.
- [15] T. Serre, L. Wolf, S. M. Bileschi, M. Riesenhuber, and T. Poggio. Robust object recognition with cortex-like mechanisms. IEEE Trans. Pattern Anal. Mach. Intell., 29(3):411 – 426, 2007.
- [16] F. Song and J. Dongarra. Scaling up matrix computations on shared-memory manycore systems with 1000 cpu cores. In Proceedings of the 28th ACM International Conference on Supercomputing, ICS '14, pages 333 – 342, New York, NY, USA, 2014. ACM.
- [17] I. Sutskever, J. Martens, G. E. Dahl, and G. E. Hinton. On the importance of initialization and momentum in deep learning. In ICML, volume 28 of JMLR Proceedings, pages 1139 – 1147. JMLR.org, 2013.

- [18] C. Szegedy, A. Toshev, and D. Erhan. Deep neural networks for object detection. In C. J. C. Burges, L. Bottou, Z. Ghahramani, and K. Q. Weinberger, editors, NIPS, pages 2553 – 2561, 2013.
- [19] A. Toshev and C. Szegedy. Deeppose: Human pose estimation via deep neural networks. CoRR, abs/1312.4659, 2013.
- [20] K. E. A. van de Sande, J. R. R. Uijlings, T. Gevers, and A. W. M. Smeulders. Segmentation as selective search for object recognition. In Proceedings of the 2011 International Conference on Computer Vision, ICCV '11, pages 1879 – 1886, Washington, DC, USA, 2011. IEEE Computer Society.
- [21] M. D. Zeiler and R. Fergus. Visualizing and understanding convolutional networks. In D. J. Fleet, T. Pajdla, B. Schiele, and T. Tuytelaars, editors, ECCV, volume 8689 of Lecture Notes in Computer Science, pages 818 – 833. Springer, 2014.