

目标检测经典论文翻译汇总：[\[翻译汇总\]](#)

翻译 pdf 文件下载：[\[下载地址\]](#)

此版为纯中文版，中英文对照版请稳步：[\[R-FCN 中英文对照版\]](#)

R-FCN: Object Detection via Region-based Fully Convolutional Networks

基于 Region 的全卷积神经网络进行目标检测

Jifeng Dai Microsoft Research	Yi Li* Tsinghua University	Kaiming He Microsoft Research	Jian Sun(孙剑) Microsoft Research
----------------------------------	-------------------------------	----------------------------------	------------------------------------

摘要

我们提出了基于 Region 的全卷积网络，以实现准确和高效的目标检测。与先前的基于区域的检测器（如 Fast/Faster R-CNN [6, 18]）相比，这些检测器每次需要对每个 region 运行非常耗时子网络，我们的基于区域的检测器是全卷积的，几乎所有计算都在整张图像上共享。为了实现这一目标，我们提出了位置敏感分数图（position-sensitive score maps），以解决图像分类中的平移不变性与目标检测中的平移可变性之间的矛盾。因此，我们的方法自然地采用全卷积图像分类器的主干网络，如最新的残差网络（ResNets）[9]，用于目标检测。我们使用 101 层 ResNet 在 PASCAL VOC 数据集上获得了具有竞争力的结果（例如，2007 数据集上 83.6% 的 mAP）。同时，我们的测试结果达到每张图像 170ms 的测试速度，比 Faster R-CNN 相应的配置速度快 2.5-20 倍。代码公开发布在：<https://github.com/daijifeng001/r-fcn>。

（译者注：上面 github 的代码为 Matlab 版，Python 版：
<https://github.com/YuwenXiong/py-R-FCN>）

1. 引言

流行的目标检测深度网络家族[8, 6, 18]通过感兴趣区域（RoI）池化层[6]可以将网络划分成两个子网络：（i）独立于 RoI 的共享“全卷积”子网络，（ii）不共享计算的 RoI 子网络。这种分解[8]以往是由开创性的分类架构产生的，例如 AlexNet[10]和 VGG Nets[23]等，在设计上它由两个子网络组成——一个卷积子网络以空间池化层结束，后面是几个全连接（fc）层。因此，图像分类网络中的（最后一个）空间池化层在目标检测网络中[8, 6, 18]自然地变成了 RoI 池化层。

但是最近最先进的图像分类网络，如残差网络（ResNets）[9]和 GoogLeNets[24, 26]都是被设计成全卷积的。通过类比，在目标检测架构中使用所有卷积层来构建共享的卷积子网络似乎是很自然的，使得 RoI 的子网络没有隐藏层。然而，对这项工作通过经验性的研究发现，这个 naive 的解决方案有相当差的检测精度，无法获得更好的分类精度。为了解决这个问题，在 ResNet 论文[9]中将 Faster R-CNN 检测器[18]的 RoI 池化层不自然地插入到两组卷积层之间——这便构建了更深的 RoI 子网络，其改善了精度，但由于非共享的逐 RoI 计算使得运行速度更低。

我们认为，前面提到的非自然设计源于图像分类任务希望增加变换不变性与目标检测希望保持平移可变性之间的矛盾。一方面，图像

水平的分类任务更希望具有平移不变性——图像内的目标位置的移动对分类结果应该是无差别的。因此，深度（全）卷积架构尽可能保持平移不变性，这一点可以从 ImageNet 分类[9, 24, 26]的主要结果中得到证实。另一方面，目标检测任务的定位表示需要一定程度上满足平移可变性。例如，在候选框内目标变换应该产生有意义的响应，用于描述候选框与目标的重叠程度。我们假设图像分类网络中较深的卷积层对平移不太敏感。为了解决这个困境，ResNet 论文的检测流程[9]将 RoI 池化层插入到卷积中——特定区域的操作打破了平移不变性，当在不同区域进行评估时，RoI 后卷积层不再是平移不变的。然而，这个设计牺牲了训练和测试效率，因为它引入了大量的区域层（表 1）。

表 1：使用 ResNet-101 的基于区域的检测器方法[9]。

	R-CNN [7]	Faster R-CNN [19, 9]	R-FCN [ours]
depth of shared convolutional subnetwork	0	91	101
depth of RoI-wise subnetwork	101	10	0

在本文中，我们开发了一个称为**基于区域的全卷积网络（R-FCN）**框架来进行目标检测。我们的网络由共享的全卷积架构组成，就像 FCN[15]一样。为了将平移可变性并入 FCN，我们通过使用一组专门的卷积层作为 FCN 输出来构建一组位置敏感的分图。这些分图中的每一个都编码相对应的空间位置信息（例如，“在目标的左边”）。在这个 FCN 的顶部，我们添加了一个位置敏感的 RoI 池化层，它从这些分图中获取信息，并且后面没有权重（卷积层或全连接层）层。整个架构是端到端的学习。所有可学习的层都是卷积层，并在整个图

像上共享计算，同时也对目标检测所需的空间信息进行了编码。图 1 阐述了其主要思想，表 1 比较了基于区域的不同检测器方法。

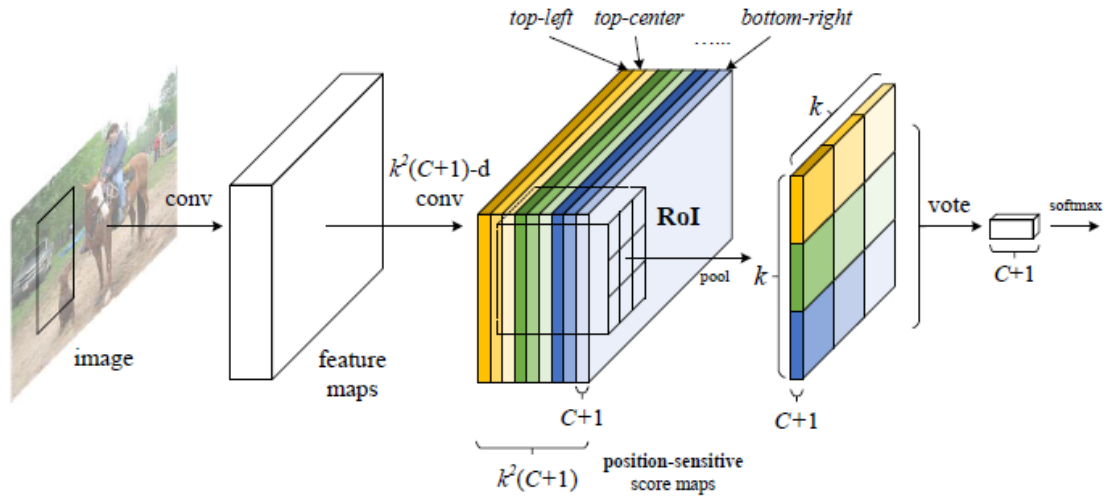


图 1: R-FCN 用于目标检测的主要思想。在这个图中，由全卷积网络生成了 $k \times k=3 \times 3$ 的位置敏感分数图。对于 RoI 中的每个 $k \times k$ bins，池化是在每个 k^2 个映射图（用不同的颜色标记）上单独进行的。

使用 101 层的残差网络(ResNet-101)[9]作为 backbone(译者注：也就是网络的主干部分，用于提取并输出输入图像的特征图)，我们的 R-FCN 在 PASCAL VOC 2007 数据集和 2012 数据集上分别获得了 83.6% 的 mAP 和 82.0% 的 mAP。同时，使用 ResNet-101 时我们的模型在测试时运行每张图像只需 170ms，比[9]中相应的 Faster R-CNN + ResNet-101 模型快了 2.5 倍到 20 倍。这些实验表明，我们的方法设法解决平移不变性/可变性之间的矛盾，并且全卷积图像水平的分类器，例如 ResNet，可以有效地转换为全卷积目标检测器。代码公开发布在：<https://github.com/daijifeng001/r-fcn>（译者注：此代码为 Matlab 版，Python 版：<https://github.com/YuwenXiong/py-R-FCN>）。

2. 我们的方法

概述。根据 R-CNN[7]，我们也采用了流行的两阶段目标检测策略[7, 8, 6, 18, 1, 22]，其中包括：(i) region proposal 和 (ii) 区域分类。尽管不依赖 region proposal 的方法确实存在(例如[17, 14])，但是基于区域的系统在几个**基准**（数据集及评估标准）[5, 13, 20]中仍然具有领先的准确性。我们使用 region proposal 网络（RPN）提取候选区域[18]，RPN 本身就是一个全卷积架构。根据[18]我们在 RPN 和 R-FCN 之间的共享特征。图 2 所示为系统的概述。




图 2: R-FCN 的总体架构。region proposal 网络（RPN）[18]产生候选 RoI，然后将其应用于评分图上。所有可学习的权重层都是卷积层，并在整个图像上进行卷积计算；每个 RoI 的计算成本可以忽略不计。

给定 proposal regions (RoI)，R-FCN 架构被设计成将 RoI 分类为目标类别和背景。在 R-FCN 中，所有可学习的权重层都是卷积层，并在整个图像上进行卷积运算。最后一个卷积层为每个类别产生一堆大小为 k^2 的位置敏感分数图 (position-sensitive score maps)，因此该层是一个具有 C 个目标类别的 $k^2(C+1)$ 通道的输出层 (+1 为背景)。这些 k^2 个分数图对应于描述相对位置的 $k \times k$ 空间格子。例如，当

$k \times k = 3 \times 3$ 时，共有大小为 9 的分数图分别编码目标类别上{上左、上中、上右、中左、中中、中右、下左、下中、下右}的位置信息。

R-FCN 最后是位置敏感的 RoI 池化层。该层聚合最后一个卷积层的输出，并为每个 RoI 生成分数。与[8, 6]不同的是，我们的位置敏感 RoI 层进行选择性的池化，对于 $k \times k$ 个 bins 中的每一个仅聚合 $k \times k$ 分数图中的其中一个分数图的响应。通过端到端的训练，这个 RoI 层使得最后一个卷积层可以学习到特定的位置敏感分数图。图 1 阐述了这个想法。图 3 和图 4 可视化了一个例子。详细介绍如下。

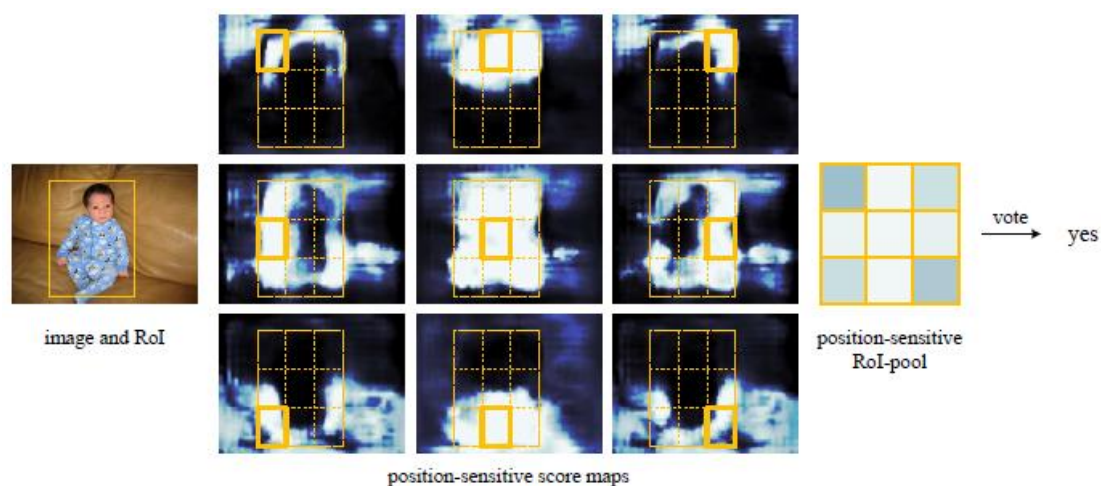


图 3：对目标类别是人的图像进行 R-FCN($k \times k = 3 \times 3$)可视化。




图 4：当 RoI 与目标没有正确地重叠时的可视化。

Backbone(网络主干)架构。本文中典型的 R-FCN 是基于 ResNet-101[9]的，但其他网络[10,23]（译者注：AlexNet、VGGNet）也适用。ResNet-101 有 100 个卷积层，后面是全局平均池化和 1000 类的全连接层。我们删除了平均池化层和全连接层，只使用卷积层来计算特征图。我们使用由[9]的作者发布的 ResNet-101，其在 ImageNet[20]上进行了预训练。ResNet-101 中的最后一个卷积块是 2048 维，我们增加一个随机初始化的 1024 维的 1×1 卷积层来进行降维（准确地说，这将表 1 中的网络深度增加了 1）。然后，我们应用 $k^2(C+1)$ 个通道的卷积层来生成分数图，如下所述。

位置敏感的分数图和位置敏感的 RoI 池化。为了将位置信息显式地编码到每个 RoI 中，我们以规则网格的方式将每个 RoI 矩形框划分成 $k \times k$ 的 bins。对于大小为 $w \times h$ 的 RoI 矩形，每个 bins 的大小约为 $w/k \times h/k$ [8,6]。在我们的方法中，构建最后的卷积层为每个类别产生 k^2 分数图。对于第 (i,j) 个 ($0 \leq i, j \leq k-1$) bin，我们定义了一个位置敏感的 RoI 池化操作，其只针对第 (i,j) 个分数图中进行池化：

$$r_c(i, j | \Theta) = \sum_{(x,y) \in \text{bin}(i,j)} z_{i,j,c}(x + x_0, y + y_0 | \Theta) / n. \quad (1)$$

这里 $r_c(i,j)$ 是第 c 个类别的第 (i,j) 个 bin 的池化结果， $z_{i,j,c}$ 是 $k^2(C+1)$ 个分数图中的一个分数图， (x_0, y_0) 表示一个 RoI 的左上角， n 是 bin 中的像素数量， Θ 表示网络中所有可学习的参数。第 (i,j) 个组块跨越 $\lfloor i \frac{w}{k} \rfloor \leq x < \lceil (i+1) \frac{w}{k} \rceil$ 和 $\lfloor j \frac{h}{k} \rfloor \leq y < \lceil (j+1) \frac{h}{k} \rceil$ 。公式 (1) 的操作如图 1 所示，其中每种颜色表示一对 (i,j) 。公式 (1) 中使用平均池化（本文中也使用平均池化），但也可以使用最大池化。

然后在 RoI 上对 k^2 个位置敏感的分数的分数进行投票。在本文中，我们通过对分数进行平均来简单地投票，为每个 RoI 产生一个 $(C+1)$ 维的向量： $\hat{r}_c(\Theta) = \sum_{i,j} r_c(i, j | \Theta)$ 。然后，我们计算跨类别的 softmax 值： $s_c(\Theta) = e^{r_c(\Theta)} / \sum_{c'=0}^C e^{r_{c'}(\Theta)}$ 。它们被用来在训练期间计算交叉熵损失，在推断期间对 RoI 进行排名。

我们以类似的方式进一步完成边界框回归[7, 6]。除了上面的 $k^2(C+1)$ 维卷积层，我们附加了一个 $4k^2$ 维的同级卷积层用于边界框回归。在这组 $4k^2$ 维特征图上进行位置敏感的 RoI 池化，为每个 RoI 生成一个 $4k^2$ 维的向量。然后通过平均投票聚合成 4 维向量中。这个 4 维向量将边界框按照[6]参数化为 $t=(t_x, t_y, t_w, t_h)$ 。我们注意到，为了简单起见我们执行类别无关的边界框回归，但类别特定的对应部分（例如，具有 $4k^2C$ 维输出层）也是适用的。

位置敏感分数图概念的一部分受到了[3]的启发，[3]开发了用于样本级语义分割的 FCN。我们进一步介绍了位置敏感的 RoI 池化层，它可以让学习的分数图用于目标检测。RoI 层之后没有可学习的层，使得区域计算几乎是零成本的，并加速了训练和推断。

训练。通过预先计算的 region proposals，很容易端到端训练 R-FCN 架构。根据[6]，我们定义的损失函数是每个 RoI 的交叉熵损失和边界框回归损失的总和：

$L(s, t_{x,y,w,h}) = L_{cls}(s_{c^*}) + \lambda[c^* > 0]L_{reg}(t, t^*)$ 。这里 c^* 是 RoI 的真实标签（ $c^*=0$ 表示背景）。 $L_{cls}(s_{c^*}) = -\log(s_{c^*})$ 是分类的交叉熵损失， L_{reg} 是[6]中定义的边界框回归损失， t^* 表示真实的边界框。

$[c^*>0]$ 是一个指示符, 如果参数为 `true`, 则等于 1, 否则为 0。与[6]一样, 我们设置平衡权重 $\lambda=1$ 。我们将正样本定义为与真实边界框重叠的交并比 (IoU) 至少为 0.5 的 ROI, 否则为负样本。

我们的方法很容易在训练期间采用在线难样本挖掘(OHEM)[22]。我们可忽略的逐 RoI 计算使得几乎零成本的样本挖掘成为可能。假设每张图像有 N 个 proposals, 在前向传播中, 我们评估所有 N 个 proposals 的损失。然后, 我们按损失对所有的 RoI (正例和负例) 进行排序, 并选择具有最高损失的 B 个 RoI。反向传播[11]是基于选定的样本进行的。由于我们每个 RoI 的计算可以忽略不计, 所以前向传播时间几乎不受 N 的影响, 与[22]中的 OHEM Fast R-CNN 相比, 其可能使训练时间加倍。我们在下一节的表 3 中提供全面的时间统计。

我们使用 0.0005 的权重衰减和 0.9 的动量。默认情况下, 我们使用单尺度训练: 调整图像的大小, 使得尺度 (图像的较短边) 为 600 像素[6, 18]。每个 GPU 处理 1 张图像, 并为反向传播选择 $B=128$ 个 RoI。我们用 8 个 GPU 来训练模型 (所以有效的最小批数据大小是 8 的倍数)。在 VOC 上我们对 R-FCN 进行 fine-tune, 使用 0.001 学习率进行 2 万次迭代和使用 0.0001 学习率进行 1 万次迭代。为了使 R-FCN 与 RPN 共享特征 (图 2), 我们采用[18]中的**四步交替训练**, 交替训练 RPN 和 R-FCN。

推断。如图 2 所示, (在一个单一尺度 600 的图像上) 得到在 RPN 和 R-FCN 之间共享的特征图。然后, RPN 部分产生 RoI, R-FCN 部分在其上评估类别分数并回归边界框。在推断过程中, 根据[18],

公平起见我们评估了 300 个 RoI。作为标准的做法，使用 0.3 的 IoU 阈值[7]通过非极大值抑制（NMS）对结果进行后处理。

空洞和步长。我们的全卷积架构享有 FCN 广泛使用的语义分割的网络修改的好处[15, 2]。特别的是，我们将 ResNet-101 的有效步长从 32 像素降低到了 16 像素，增加了分数图的分辨率。conv4 阶段[9]（stride = 16）及之前的所有层都保持不变；第一个 conv5 块中的 stride=2 操作被修改为 stride=1，并且 conv5 阶段的所有卷积卷积核都被修改为“hole algorithm”[15,2]（“Algorithm atrous”[16]）以弥补减少的步幅。为了进行公平的比较，RPN 是在 conv4 阶段（与 R-FCN 共享）之上计算的，就像[9]中 Faster R-CNN 的情况那样，所以 RPN 不会受空洞技巧（atrous trick）的影响。下表显示了 R-FCN 的消融研究结果（ $k \times k=7 \times 7$ ，没有进行难样本挖掘）。这个空洞技巧提高了 2.6 点的 mAP。

R-FCN with ResNet-101 on:	conv4, stride=16	conv5, stride=32	conv5, à trous, stride=16
mAP (%) on VOC 07 test	72.5	74.0	76.6

可视化。在图 3 和图 4 中，我们使用 $k \times k=3 \times 3$ 并可视化了 R-FCN 学习的位置敏感分数图。期望这些特定的分数图将在目标特定的相对位置被强激活。例如，“上中敏感”分数图大致在目标的顶部中心位置附近呈现高分。如果一个候选框与一个真实目标精确地重叠（图 3），则 RoI 中 k^2 个 bins 的大部分都被强烈地激活，并且他们的投票获得较高的分数。相反，如果一个候选框与一个真实目标没有正确的重叠（图 4），那么 RoI 中的 k^2 个 bins 的一些没有被激活，最终导致投票分数也很低。

3. 相关工作

R-CNN[7]已经证明了在深度网络中使用 region proposals[27, 28]的有效性。R-CNN 在裁剪区域和变形区域上进行卷积，卷积计算不在区域之间共享(表 1)。SPPnet[8]、Fast R-CNN[6]和 Faster R-CNN[18]是“半卷积”共享的，因为其中一个卷积子网络在整张图像上进行共享计算，另一个子网络是在每个单独区域上进行卷积运算。

较早之前已经存在“全卷积”模型的目标检测器。OverFeat[21]通过在共享卷积特征图上滑动多尺度窗口来检测目标（译者注：OverFeat 使用滑动窗口的方式产生 region）；同样地，在 Fast R-CNN[6]和[12]中，研究了用滑动窗口替代 region proposals。在这些案例中，可以将一个单尺度的滑动窗口重新设计为单个卷积层。Faster R-CNN[18]中的 RPN 组件是一个全卷积检测器，它可以相对于多个尺寸的参考框（anchors）预测边界框。[18]中最初的 RPN 是类别无关的，但是它的相对应的类别特定的也是适用的（参见[14]），我们在下面进行了评估。

另一个目标检测器家族采用全连接（fc）层来在整张图像上生成整体的目标检测结果，如[25, 4, 17]（译者注：17 为 YOLOv1）。

4. 实验

4.1 PASCAL VOC 上的实验

我们在有 20 个目标类别的 PASCAL VOC[5]上进行了实验。我们根据[6]在 VOC 2007 trainval 和 VOC 2012 trainval（“07 + 12”）的

联合数据集上进行了训练，并在 VOC 2007 测试集上进行了评估。目标检测精度通过 mAP 来度量。




图 5: R-FCN 在 PASCAL VOC 2007 测试集 (83.6% mAP) 上结果的精选示例。网络是 ResNet-101，训练数据是 07 + 12 + COCO。得分大于阈值 0.6 时显示。在 Nvidia K40 GPU 上每张图像的运行时间为 170ms。

与其它全卷积策略的比较

虽然全卷积检测器是可以实现的，但是实验表明它们要达到良好的精度并非简单。我们使用 ResNet-101 研究了以下全卷积策略（或“几乎”全卷积的策略，即每个 RoI 只有一个分类器的全连接层）：

Naive Faster R-CNN。如引言中的讨论，可以使用 ResNet-101 中的所有卷积层来计算共享特征图，并且在最后的卷积层(conv5 之后)之后采用 RoI 池化。在每个 RoI 上评估一个廉价的 21 个类别的全连接层（所以这个变体是“几乎”全卷积的）。为了比较的公平使用了空洞技巧。

类别特定的 RPN。这个 RPN 按照[18]进行了训练，除了两类（是目标或不是目标）的卷积分类器层被替换为 21 类卷积分类器层。为了公平地比较，对于这个类别特定的 RPN，我们对 ResNet-101 中的 conv5 层使用空洞技巧。

不使用位置敏感的 R-FCN。通过设置 $k=1$ ，我们移除了 R-FCN 中位置敏感的结构部分。这相当于在每个 RoI 上进行全局池化。

分析。表 2 显示了结果。我们注意到 ResNet 论文[9]中标准（非 naive）的 Faster R-CNN 与 ResNet-101（参见表 3）达到了 76.4%的 mAP，在 conv4 和 conv5 之间插入了 RoI 池化层[9]。相比之下，naive 的 Faster R-CNN（在 conv5 之后应用 RoI 池化）具有 68.9%的更低的 mAP（表 2）。这种比较通过在 Faster R-CNN 系统的层之间插入 RoI 池化并在经验上证明了保留空间信息的重要性。在[19]中报道了类似的观察结果。

表 2: 使用 ResNet-101 的全卷积（或“几乎”全卷积）策略之间的比较。表中的所有对比模型都使用了空洞技巧。不进行难样本挖掘。

method	RoI output size ($k \times k$)	mAP on VOC 07 (%)
naïve Faster R-CNN	1×1 7×7	61.7 68.9
class-specific RPN	-	67.6
R-FCN (w/o position-sensitivity)	1×1	fail
R-FCN	3×3 7×7	75.5 76.6

表 3: 使用 ResNet-101 比较 Faster R-CNN 和 R-FCN。在单个 Nvidia K40 GPU 上进行了时间评估。采用 OHEM 时, 在前向传播中计算每张图像的 N 个 RoI, 并且选择 128 个 RoIs 用于反向传播。根据[18], 测试时使用了 300 个 RoI。

	depth of per-RoI subnetwork	training w/ OHEM?	train time (sec/img)	test time (sec/img)	mAP (%) on VOC07
Faster R-CNN	10		1.2	0.42	76.4
R-FCN	0		0.45	0.17	76.6
Faster R-CNN	10	✓ (300 RoIs)	1.5	0.42	79.3
R-FCN	0	✓ (300 RoIs)	0.45	0.17	79.5
Faster R-CNN	10	✓ (2000 RoIs)	2.9	0.42	N/A
R-FCN	0	✓ (2000 RoIs)	0.46	0.17	79.3

类别特定的 RPN 具有 67.6%（表 2）的 mAP，比标准 Faster R-CNN 的 76.4% 低约 9 个百分点。这个比较与[6, 12]中的观测结果一致——实际上，类别特定的 RPN 类似于使用密集滑动窗口作为 proposals 的一种特殊形式的 Fast R-CNN[6]，如[6, 12]中所报道的较差结果。

另一方面，我们的 R-FCN 系统具有更好的准确性（表 2）。其 mAP（76.6%）与标准 Faster R-CNN（76.4%，表 3）基本相当。这些结果表明，我们的位置敏感策略设法编码有用的空间信息来定位目标，而在 RoI 池化之后不使用任何可学习的层。

位置敏感性的重要性通过设置 $k=1$ 进一步进行了证明，此时 R-FCN 不能收敛。在这种退化的情况下，在 RoI 内不能显式捕获空间信息。此外，我们研究表明如果 naïve Faster R-CNN 的 ROI 池化输出分

辨率为 1×1 ，其能够收敛，但是其 mAP 会进一步下降一大截至 61.7%（表 2）。

与使用 ResNet-101 的 Faster R-CNN 的比较

接下来，我们与标准的“Faster R-CNN + ResNet-101”[9]进行比较，它是 PASCAL VOC、MS COCO 和 ImageNet 基准测试中最强劲的竞争对手和最佳表现者。我们在下面的实验中使用 $k \times k = 7 \times 7$ 。表 3 显示了比较结果。Faster R-CNN 评估了每个区域的 10 层子网络以达到良好的精度，但是 R-FCN 每个区域的成本可以忽略不计。在测试时使用 300 个 RoI，Faster R-CNN 每张图像花费 0.42s，比我们的 R-FCN 慢了 2.5 倍，R-FCN 每张图像只有 0.17s（在 K40 GPU 上，这个数字在 Titan X GPU 上是 0.11s）。R-FCN 的训练速度也快于 Faster R-CNN。此外，难样本挖掘[22]没有增加 R-FCN 的训练成本（表 3）。当从 2000 个 RoI 进行难样本挖掘时训练 R-FCN 是可行的，在这种情况下，Faster R-CNN 慢了 6 倍（2.9s vs. 0.46s）。但是实验表明，从更大的候选集（例如 2000）中进行难样本挖掘是没有好处的（表 3）。所以我们在本文的其他部分使用了 300 个 RoI 来进行训练和推断。

表 4 显示了更多的比较。根据[8]中的多尺度训练，我们在每次训练迭代中调整图像大小，使得尺度从{400, 500, 600, 700, 800}像素中进行随机地采样。我们测试时仍然使用 600 像素的单尺度，所以不添加测试时间成本。mAP 是 80.5%。此外，我们在 MS COCO [13]训练验证集上训练我们的模型，然后在 PASCAL VOC 数据集上对其进行 fine-tune。R-FCN 达到 83.6% 的 mAP（表 4），该结果接近[9]中同样

使用 ResNet-101 的 “Faster R-CNN +++” 系统。我们注意到，我们的对比结果是在每张图像 0.17 秒的测试速度下获得的，比花费 3.36 秒的 Faster R-CNN +++ 快 20 倍，因为它进一步结合了迭代边界框回归、上下文和多尺度测试[9]。在 PASCAL VOC 2012 测试集上也观察到了类似的结果（表 5）。

表 4: 使用 ResNet-101 在 PASCAL VOC 2007 测试集上的比较。“Faster R-CNN +++” [9]使用迭代边界框回归、上下文和多尺度测试。

	training data	mAP (%)	test time (sec/img)
Faster R-CNN [9]	07+12	76.4	0.42
Faster R-CNN +++ [9]	07+12+COCO	85.6	3.36
R-FCN	07+12	79.5	0.17
R-FCN multi-sc train	07+12	80.5	0.17
R-FCN multi-sc train	07+12+COCO	83.6	0.17

表 5: 使用 ResNet-101 在 PASCAL VOC 2012 测试集上的比较。“07 ++ 12” [6] 表示 07 训练 + 测试和 12 训练的联合数据集。† : <http://host.robots.ox.ac.uk:8080/anonymous/44L5HI.html> ‡ : <http://host.robots.ox.ac.uk:8080/anonymous/MVCM2L.html>

	training data	mAP (%)	test time (sec/img)
Faster R-CNN [9]	07++12	73.8	0.42
Faster R-CNN +++ [9]	07++12+COCO	83.8	3.36
R-FCN multi-sc train	07++12	77.6 [†]	0.17
R-FCN multi-sc train	07++12+COCO	82.0 [‡]	0.17

关于深度的影响

下表显示了使用不同深度的 ResNets 的 R-FCN 结果[9]。当深度从 50 增加到 101 时，我们的检测精度增加了，但是深度 152 时达到了饱和。

	training data	test data	ResNet-50	ResNet-101	ResNet-152
R-FCN	07+12	07	77.0	79.5	79.6
R-FCN multi-sc train	07+12	07	78.7	80.5	80.4

关于 region proposals 的影响

R-FCN 可以很容易地应用于其它的 region proposals 方法，如 Selective Search (SS) [27]和 Edge Boxes (EB) [28]。下表显示了使用不同 proposals 的结果（使用 ResNet-101）。R-FCN 使用不同的 SS 或 EB，结果展示了我们方法的泛化性。

	training data	test data	RPN [18]	SS [27]	EB [28]
R-FCN	07+12	07	79.5	77.2	77.8

表 7: PASCAL VOC 2007 测试集上详细的检测结果

method	data	mAP	areo	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
Faster R-CNN	07+12	76.4	79.8	80.7	76.2	68.3	55.9	85.1	85.3	89.8	56.7	87.8	69.4	88.3	88.9	80.9	78.4	41.7	78.6	79.8	85.3	72.0
Faster R-CNN+++	07+12+CO	85.6	90.0	89.6	87.8	80.8	76.1	89.9	89.9	89.6	75.5	90.0	80.7	89.6	90.3	89.1	88.7	65.4	88.1	85.6	89.0	86.8
R-FCN	07+12	79.5	82.5	83.7	80.3	69.0	69.2	87.5	88.4	88.4	65.4	87.3	72.1	87.9	88.3	81.3	79.8	54.1	79.6	78.8	87.1	79.5
R-FCN ms train	07+12	80.5	79.9	87.2	81.5	72.0	69.8	86.8	88.5	89.8	67.0	88.1	74.5	89.8	90.6	79.9	81.2	53.7	81.8	81.5	85.9	79.9
R-FCN ms train	07+12+CO	83.6	88.1	88.4	81.5	76.2	73.8	88.7	89.7	89.6	71.1	89.9	76.6	90.0	90.4	88.7	86.6	59.7	87.4	84.1	88.7	82.4

表 8: PASCAL VOC 2012 测试集上详细的检测结果。y: <http://host.robots.ox.ac.uk:8080/anonymous/44L5HI.html> z: <http://host.robots.ox.ac.uk:8080/anonymous/MVCM2L.html>

method	data	mAP	areo	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
Faster R-CNN	07++12	73.8	86.5	81.6	77.2	58.0	51.0	78.6	76.6	93.2	48.6	80.4	59.0	92.1	85.3	84.8	80.7	48.1	77.3	66.5	84.7	65.6
Faster R-CNN+++	07++12+CO	83.8	92.1	88.4	84.8	75.9	71.4	86.3	87.8	94.2	66.8	89.4	69.2	93.9	91.9	90.9	89.6	67.9	88.2	76.8	90.3	80.0
R-FCN ms train [†]	07++12	77.6	86.9	83.4	81.5	63.8	62.4	81.6	81.1	93.1	58.0	83.8	60.8	92.7	86.0	84.6	84.4	59.0	80.8	68.6	86.1	72.9
R-FCN ms train [‡]	07++12+CO	82.0	89.5	88.3	83.5	70.8	70.7	85.5	86.3	94.2	64.7	87.6	65.8	92.7	90.5	89.4	87.8	65.6	85.6	74.5	88.9	77.4

4.2 MS COCO 上的实验

接下来，我们评估 MS COCO 数据集[13]中的 80 个目标类别。我们的实验包括 8 万张训练集、4 万张验证集和 2 万张 test-dev。我们设置学习率为 0.001 进行 9 万次迭代，紧接着设置学习率为 0.0001 进行 3 万次迭代，有效的 mini 批大小为 8（译者注：使用 8 个 GPU，每个 GPU 负责处理 1 张图像，因此批大小为 8 的倍数）。我们将交替训练[18]从 4 步扩展到 5 步（即在多训练一轮 RPN 后停止），当特征图被共享时略微提高了在该数据集上的准确性；我们还报告了两步训练足以达到相当好的准确性，但不共享这些特征。




图 6: R-FCN 在 MS COCO test-dev 数据集 (31.5% mAP) 上结果的精选示例。网络是 ResNet-101, 训练数据是 MS COCO trainval。得分大于阈值 0.6 时显示。在 Nvidia K40 GPU 上每张图像的运行时间为 170ms。

结果如表 6 所示。我们单尺度训练的 R-FCN 基准模型的验证结果为 48.9%/27.6%。这与 Faster R-CNN 的基准模型相当(48.4%/27.2%), 但我们的测试速度是 Faster R-CNN 的 2.5 倍。值得注意的是, 我们的方法在小尺寸的目标(由[13]定义)上表现更好。我们多尺度训练(但测试时仍然为单尺度)的 R-FCN 在验证集上的结果为 49.1%/27.8%,

在 test-dev 上的结果是 51.5%/29.2%。考虑到 COCO 较宽范围的目标尺度，按照[9]我们进一步评估多尺度的测试变体模型，并使用{200, 400, 600, 800, 1000}的测试尺度。mAP 是 53.2%/31.5%。这个结果接近 MS COCO 2015 比赛中第一名的成绩(使用 ResNet-101 的 Faster R-CNN+++, 55.7%/34.9%)。尽管如此，我们的方法更简单，并且没有添加[9]中所使用的一些花里胡哨的东西，例如上下文或迭代边界框回归等，并且在训练和测试中速度更快。

表 6: 使用 ResNet-101 在 MS COCO 数据集上比较。COCO 标准的 AP 在 $\text{IoU} \in [0.5, 0.95]$ 上进行了评估。AP@0.5 是 PASCAL 标准的 AP，其在 @IoU=0.5 上进行评估。

	training data	test data	AP@0.5	AP	AP small	AP medium	AP large	test time (sec/img)
Faster R-CNN [9]	train	val	48.4	27.2	6.6	28.6	45.0	0.42
R-FCN	train	val	48.9	27.6	8.9	30.5	42.0	0.17
R-FCN multi-sc train	train	val	49.1	27.8	8.8	30.8	42.2	0.17
Faster R-CNN +++ [9]	trainval	test-dev	55.7	34.9	15.6	38.7	50.9	3.36
R-FCN	trainval	test-dev	51.5	29.2	10.3	32.4	43.3	0.17
R-FCN multi-sc train	trainval	test-dev	51.9	29.9	10.8	32.8	45.0	0.17
R-FCN multi-sc train, test	trainval	test-dev	53.2	31.5	14.3	35.5	44.2	1.00

5. 结论和将来的工作

我们提出了基于区域的全卷积网络，这是一个简单但精确且高效的目标检测框架。我们的系统自然地采用了设计为全卷积的最先进的图像分类骨干网络，如 ResNet。我们的方法获得了与 Faster R-CNN 对应网络相比更具竞争力的准确性，但是在训练和推断上速度都快很多。

我们故意保持 R-FCN 系统如论文中介绍的那样简单。已经有一系列针对语义分割（例如，参见[2]）开发的 FCN 的正交扩展，以及基于区域的用于目标检测方法的扩展（例如参见[9, 1, 22]）。我们期望我们的系统能够轻松享有这个领域的进步带来的好处。

参考文献

- [1] S. Bell, C. L. Zitnick, K. Bala, and R. Girshick. Inside-outside net: Detecting objects in context with skip pooling and recurrent neural networks. In CVPR, 2016.
- [2] L.-C. Chen, G. Papandreou, I. Kokkinos, K. Murphy, and A. L. Yuille. Semantic image segmentation with deep convolutional nets and fully connected crfs. In ICLR, 2015.
- [3] J. Dai, K. He, Y. Li, S. Ren, and J. Sun. Instance-sensitive fully convolutional networks. arXiv:1603.08678, 2016.
- [4] D. Erhan, C. Szegedy, A. Toshev, and D. Anguelov. Scalable object detection using deep neural networks. In CVPR, 2014.
- [5] M. Everingham, L. Van Gool, C. K. Williams, J. Winn, and A. Zisserman. The PASCAL Visual Object Classes (VOC) Challenge. IJCV, 2010.
- [6] R. Girshick. Fast R-CNN. In ICCV, 2015.
- [7] R. Girshick, J. Donahue, T. Darrell, and J. Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In CVPR, 2014.
- [8] K. He, X. Zhang, S. Ren, and J. Sun. Spatial pyramid pooling in deep convolutional networks for visual recognition. In ECCV. 2014.
- [9] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In CVPR, 2016.
- [10] A. Krizhevsky, I. Sutskever, and G. Hinton. Imagenet classification with deep convolutional neural networks. In NIPS, 2012.
- [11] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel. Backpropagation applied to handwritten zip code recognition. Neural computation, 1989.
- [12] K. Lenc and A. Vedaldi. R-CNN minus R. In BMVC, 2015.
- [13] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick. Microsoft COCO: Common objects in context. In ECCV, 2014.
- [14] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, and S. Reed. SSD: Single shot multibox detector. arXiv:1512.02325v2, 2015.
- [15] J. Long, E. Shelhamer, and T. Darrell. Fully convolutional networks for semantic segmentation. In CVPR, 2015.
- [16] S. Mallat. A wavelet tour of signal processing. Academic press, 1999.
- [17] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi. You only look once: Unified, real-time object detection. In CVPR, 2016.
- [18] S. Ren, K. He, R. Girshick, and J. Sun. Faster R-CNN: Towards real-time object detection with region proposal networks. In NIPS, 2015.
- [19] S. Ren, K. He, R. Girshick, X. Zhang, and J. Sun. Object detection networks on convolutional feature maps. arXiv:1504.06066, 2015.
- [20] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei. ImageNet Large Scale Visual Recognition Challenge. IJCV, 2015.

- [21] P. Sermanet, D. Eigen, X. Zhang, M. Mathieu, R. Fergus, and Y. LeCun. Overfeat: Integrated recognition, localization and detection using convolutional networks. In ICLR, 2014.
- [22] A. Shrivastava, A. Gupta, and R. Girshick. Training region-based object detectors with online hard example mining. In CVPR, 2016.
- [23] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In ICLR, 2015.
- [24] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, and A. Rabinovich. Going deeper with convolutions. In CVPR, 2015.
- [25] C. Szegedy, A. Toshev, and D. Erhan. Deep neural networks for object detection. In NIPS, 2013.
- [26] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna. Rethinking the inception architecture for computer vision. In CVPR, 2016.
- [27] J. R. Uijlings, K. E. van de Sande, T. Gevers, and A. W. Smeulders. Selective search for object recognition. IJCV, 2013.
- [28] C. L. Zitnick and P. Dollár. Edge boxes: Locating object proposals from edges. In ECCV, 2014.