

图像分类经典论文翻译汇总：[\[翻译汇总\]](#)

翻译 pdf 文件下载：[\[下载地址\]](#)

此版为纯中文版，中英文对照版请稳步：[\[VGGNet 中英文对照版\]](#)

Very Deep Convolutional Networks for Large-Scale Image Recognition

用于大规模图像识别的深度卷积网络

Karen Simonyan^{*} & Andrew Zisserman[†]

Visual Geometry Group, Department of Engineering Science, University of
Oxford(牛津大学工程科学系视觉几何组)

{karen,az}@robots.ox.ac.uk

摘要

在这项工作中，我们研究了卷积网络深度在大规模的图像识别环境下对准确性的影响。我们的主要贡献是使用非常小的（ 3×3 ）卷积滤波器架构对网络深度的增加进行了全面评估，这表明通过将深度推到 16-19 加权层可以实现对现有技术配置的显著改进。这些发现是我们的 ImageNet Challenge 2014 提交论文的基础，我们的团队在定位和分类过程中分别获得了第一名和第二名。我们还表明，我们的表示对于其他数据集泛化的很好，在其它数据集上取得了最好的结果。我们使我们的两个性能最好的 ConvNet 模型可公开获得，以便进一步研究计算机视觉中深度视觉表示的使用。

1 引言

卷积网络（ConvNets）近来在大规模图像和视频识别方面取得了巨大成功（Krizhevsky 等，2012；Zeiler&Fergus，2013；Sermanet 等，2014；Simonyan & Zisserman，2014），由于大的公开图像存储库，例如 ImageNet，以及高性能计算

^{*} current affiliation: Google DeepMind

^{*} 目前所属机构：Google DeepMind

[†] current affiliation: University of Oxford and Google DeepMind

[†] 目前所属机构：牛津大学、Google DeepMind

系统的出现，例如 GPU 或大规模分布式集群（Dean 等，2012）使这成为可能。特别是，在深度视觉识别架构的进步中，ImageNet 大型视觉识别挑战（ILSVRC）（Russakovsky 等，2014）发挥了重要作用，它已经成为几代大规模图像分类系统的测试平台，从高维度浅层特征编码（Perronnin 等，2010）（ILSVRC-2011 的获胜者）到深层 ConvNets（Krizhevsky 等，2012）（ILSVRC-2012 的获奖者）。

随着 ConvNets 在计算机视觉领域越来越商品化，为了达到更好的准确性，已经进行了许多尝试来改进 Krizhevsky 等人（2012）最初的架构。例如，ILSVRC-2013（Zeiler & Fergus，2013；Sermanet 等，2014）表现最佳的论文使用了更小的感受野窗口尺寸和第一卷积层更小的步长。另一条改进措施在整个图像和多个尺度上对网络进行密集地训练和测试（Sermanet 等，2014；Howard，2014）。在本文中，我们讨论了 ConvNet 架构设计的另一个重要方面——其深度。为此，我们修正了架构的其它参数，并通过添加更多的卷积层来稳定地增加网络的深度，这是可行的，因为在所有层中使用非常小的（ 3×3 ）卷积滤波器。

因此，我们提出了更为精确的 ConvNet 架构，不仅可以在 ILSVRC 分类和定位任务上取得的最佳的准确性，而且还适用于其它的图像识别数据集，它们可以获得优异的性能，即使使用相对简单流程的一部分（例如，通过线性 SVM 分类深度特征而不进行微调）。我们发布了两款表现最好的模型¹，以便进一步研究。

本文的其余部分组织如下。在第 2 节，我们描述了我们的 ConvNet 配置。图像分类训练和评估的细节在第 3 节，并在第 4 节中在 ILSVRC 分类任务上对配置进行了比较。第 5 节总结了论文。为了完整起见，我们还将附录 A 中描述和评估我们的 ILSVRC-2014 目标定位系统，并在附录 B 中讨论了非常深的特征在其它数据集上的泛化。最后，附录 C 包含了主要的论文修订列表。

2. ConvNet 配置

为了衡量 ConvNet 深度在公平环境中所带来的改进，我们所有的 ConvNet 层配置都使用相同的规则，灵感来自 Ciresan 等（2011）；Krizhevsky 等人（2012 年）。在本节中，我们首先描述我们的 ConvNet 配置的通用设计（第 2.1 节），

然后详细说明评估中使用的具体配置（第 2.2 节）。最后，我们的设计选择将在 2.3 节进行讨论并与现有技术进行比较。

2.1 架构

在训练期间，我们的 ConvNet 的输入是固定大小的 224×224 RGB 图像。我们唯一的预处理是从每个像素中减去在训练集上计算的 RGB 均值。图像通过一堆卷积（conv.）层，我们使用感受野很小的滤波器： 3×3 （这是捕获左/右，上/下，中心概念的最小尺寸）。在其中一种配置中，我们还使用了 1×1 卷积滤波器，可以看作输入通道的线性变换（后面是非线性）。卷积步长固定为 1 个像素；卷积层输入的空间填充要满足卷积之后保留空间分辨率，即 3×3 卷积层的填充为 1 个像素。空间池化由五个最大池化层进行，这些层在一些卷积层之后（不是所有的卷积层之后都是最大池化）。在 2×2 像素窗口上进行最大池化，步长为 2。

一堆卷积层（在不同架构中具有不同深度）之后是三个全连接（FC）层：前两个每个都有 4096 个通道，第三个执行 1000 维 ILSVRC 分类，因此包含 1000 个通道（一个通道对应一个类别）。最后一层是 soft-max 层。所有网络中全连接层的配置是相同的。

所有隐藏层都配备了修正（ReLU（Krizhevsky 等，2012））非线性。我们注意到，我们的网络（除了一个）都不包含局部响应归一化（LRN）（Krizhevsky 等，2012）：将在第 4 节看到，这种规范化并不能提高在 ILSVRC 数据集上的性能，但增加了内存消耗和计算时间。在应用的地方，LRN 层的参数是（Krizhevsky 等，2012）的参数。

2.2 配置

本文中评估的 ConvNet 配置在表 1 中列出，每列一个。接下来我们将按网络名称（A-E）来表示网络。所有配置都遵循 2.1 节提出的通用设计，并且仅是深度不同：从网络 A 中的 11 个加权层（8 个卷积层和 3 个全连接层）到网络 E 中的 19 个加权层（16 个卷积层和 3 个全连接层）。卷积层的宽度（通道数）相当小，从第一层中的 64 开始，然后在每个最大池化层之后增加 2 倍，直到达到 512。

表 1. ConvNet 配置（以列显示）。随着更多的层被添加，配置的深度从左（A）增加到右（E）（添加的层以粗体显示）。卷积层参数表示为“conv{感受野大小}-{通道数}”。为了简洁起见，不显示 ReLU 激活功能。

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

在表 2 中，我们列出了每个配置的参数数量。尽管深度很大，我们的网络中权重数量并不大于具有更大卷积层宽度和感受野的较浅网络中的权重数量（144M 的权重在（Sermanet 等人，2014）中）。

表 2: 参数数量（百万级别）

Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

2.3 讨论

我们的 ConvNet 配置与 ILSVRC-2012 (Krizhevsky 等, 2012) 和 ILSVRC-2013 比赛 (Zeiler&Fergus, 2013; Sermanet 等, 2014) 表现最佳的参赛提交中使用的 ConvNet 配置有很大不同。不是在第一卷积层中使用相对较大的感受野 (例如, 在 (Krizhevsky 等人, 2012) 中的 11×11 , 步长为 4, 或在 (Zeiler&Fergus, 2013; Sermanet 等, 2014) 中的 7×7 , 步长为 2), 我们在整个网络使用非常小的 3×3 感受野, 与输入在每个像素 (步长为 1) 进行卷积。很容易看到两个 3×3 卷积层堆叠 (没有空间池化) 有 5×5 的有效感受野; 三个这样的层具有 7×7 的有效感受野。那么我们获得了什么? 例如通过使用三个 3×3 卷积层的堆叠来替换单个 7×7 层。首先, 我们结合了三个非线性修正层, 而不是单一的, 这使得决策函数更具判别性。其次, 我们减少参数的数量: 假设三层 3×3 卷积堆叠的输入和输出有 C 个通道, 堆叠卷积层的参数为 $3(3^2C^2)=27C^2$ 个权重; 同时, 单个 7×7 卷积层将需要 $7^2C^2=49C^2$ 个参数, 即参数多 81%。这可以看作是对 7×7 卷积滤波器进行正则化, 迫使它们通过 3×3 滤波器 (在它们之间注入非线性) 进行分解。

结合 1×1 卷积层 (配置 C, 表 1) 是增加决策函数非线性而不影响卷积层感受野的一种方式。即使在我们的案例下, 1×1 卷积基本上是在相同维度空间上的线性投影 (输入和输出通道的数量相同), 由修正函数引入附加的非线性。应该注意的是 1×1 卷积层最近在 Lin 等人(2014)的 “Network in Network” 架构中已经得到了使用。

Ciresan 等人 (2011) 以前使用小尺寸的卷积滤波器, 但是他们的网络深度远远低于我们的网络, 并且他们没有在大规模的 ILSVRC 数据集上进行评估。Goodfellow 等人 (2014) 在街道号码识别任务中采用深层 ConvNets (11 个权重层), 并且其表明增加深度取得了更好的性能。GooLeNet (Szegedy 等, 2014) 是 ILSVRC-2014 分类任务的表现最好的项目, 是独立于我们工作之外开发的, 但是类似的是它也是基于非常深的卷积网络 (22 个权重层) 和小卷积滤波器 (除了 3×3 , 它们也使用了 1×1 和 5×5 卷积)。然而, 它们的网络拓扑结构比我们的更复杂, 并且在第一层中特征图的空间分辨率被大幅度地减少, 以减少计算

量。正如将在第 4.5 节显示的那样，我们的模型在单网络分类精度方面胜过 Szegedy 等人（2014）。

3 分类框架

在上一节中，我们介绍了我们的网络配置的细节。在本节中，我们将介绍分类卷积网络训练和评估的细节。

3.1 训练

ConvNet 训练过程基本上遵循 Krizhevsky 等人（2012）的做法（除了从多尺度训练图像中对输入裁剪图像进行采样外，如下文所述）。也就是说，通过使用具有动量的小批量梯度下降（基于反向传播（LeCun 等人，1989））优化多项式逻辑回归目标函数来进行训练。批量大小设为 256，动量为 0.9。训练通过权重衰减（L2 惩罚乘子设定为 $5 \cdot 10^{-4}$ ）进行正则化，前两个全连接层采取 dropout 正则化（dropout 比率设定为 0.5）。学习率初始设定为 10^{-2} ，然后当验证集准确率停止改善时，学习率以 10 倍的比率进行减小。学习率总共降低 3 次，学习在 37 万次迭代后停止（74 个 epochs）。我们推测，尽管与（Krizhevsky 等，2012）的网络相比我们的网络参数更多，网络的深度更深，但网络需要更小的 epoch 就可以收敛，这是由于（a）更大的深度和更小的卷积滤波器尺寸引起的隐式正则化，（b）某些层的预初始化。

网络权重的初始化是重要的，由于深度网络中梯度的不稳定，不好的初始化可能会阻碍学习。为了规避这个问题，我们开始训练配置 A（表 1）的网络，其深度足够浅故以随机初始化进行训练。然后，当训练更深的网络架构时，我们用网络 A 的层初始化前四个卷积层和最后三个全连接层（中间层被随机初始化）。我们没有减少预初始化层的学习率，允许他们在学习过程中改变。对于随机初始化（如果应用），我们从均值为 0 和方差为 10^{-2} 的正态分布中采样权重。偏置初始化为零。值得注意的是，在提交论文之后，我们发现可以通过使用 Glorot & Bengio（2010）的随机初始化程序来初始化权重而不进行预训练。

为了获得固定大小的 224×224 ConvNet 输入图像，它们从归一化的训练图像中被随机裁剪（每个图像每次 SGD 迭代进行一次裁剪）。为了进一步增强训

练集,裁剪图像经过了随机水平翻转和随机 RGB 颜色偏移(Krizhevsky 等,2012)。

下面解释训练图像归一化。

训练图像大小。令 S 是等轴归一化的训练图像的最小边,ConvNet 输入从 S 中裁剪(我们也将 S 称为训练尺度)。虽然裁剪尺寸固定为 224×224 ,但原则上 S 可以是不小于 224 的任何值:对于 $S=224$,裁剪图像将捕获整个图像的统计数据,完全扩展训练图像的最小边;对于 $S \gg 224$,裁剪图像将对应于图像的一小部分,包含一个小对象或对象的一部分。

我们考虑两种方法来设置训练尺度 S 。第一种是修正对应单尺度训练的 S (注意,采样裁剪图像中的图像内容仍然可以表示多尺度图像统计)。在我们的实验中,我们评估了以两个固定尺度训练的模型: $S=256$ (已经在现有技术中广泛使用(Krizhevsky 等人,2012; Zeiler&Fergus, 2013; Sermanet 等, 2014))和 $S=384$ 。给定一个 ConvNet 配置,我们首先使用 $S=256$ 来训练网络。为了加速 $S=384$ 网络的训练,用 $S=256$ 预训练的权重来进行初始化,我们使用较小的初始学习率 10^{-3} 。

设置 S 的第二种方法是多尺度训练,其中每个训练图像通过从一定范围 $[S_{\min}, S_{\max}]$ (我们使用 $S_{\min}=256$ 和 $S_{\max}=5122$)随机采样 S 来单独进行归一化。由于图像中的目标可能具有不同的大小,因此在训练期间考虑到这一点是有益的。这也可以看作是通过尺度抖动进行训练集增强,其中单个模型被训练在一定尺度范围内识别对象。为了速度的原因,我们通过对具有相同配置的单尺度模型的所有层进行微调,训练了多尺度模型,并用固定的 $S=384$ 进行预训练。

3.2 测试

在测试时,给出训练的 ConvNet 和一个输入图像,它按以下方式分类。首先,将其等轴地归一化到预定义的最小图像边,表示为 Q (我们也将其称为测试尺度)。我们注意到, Q 不一定等于训练尺度 S (正如我们在第 4 节中所示,每个 S 使用 Q 的几个值会改进性能)。然后,网络以类似于(Sermanet 等人, 2014)的方式密集地应用于归一化的测试图像上。即全连接层首先被转换成卷积层(第一 FC 层转换到 7×7 卷积层,最后两个 FC 层转换到 1×1 卷积层)。然后将所

得到的全卷积网络应用于整个（未裁剪）图像上。结果是类得分图的通道数等于类别的数量，以及取决于输入图像大小的可变空间分辨率。最后，为了获得图像的分类分数的固定大小的向量，类得分图在空间上平均（和池化）。我们还通过水平翻转图像来增强测试集：将原始图像和翻转图像的 `soft-max` 类后验进行平均，以获得图像的最终分数。

由于全卷积网络被应用在整个图像上，所以不需要在测试时对采样多个裁剪图像（Krizhevsky 等，2012），因为它需要网络重新计算每个裁剪图像，这样效率较低。同时，如 Szegedy 等人（2014）所做的那样，使用大量的裁剪图像可以提高准确度，因为与全卷积网络相比，它使输入图像的采样更精细。此外，由于不同的卷积边界条件，多裁剪图像评估是密集评估的补充：当将 ConvNet 应用于裁剪图像时，卷积特征图用零填充，而在密集评估的情况下，相同裁剪图像的填充自然会来自于图像的相邻部分（由于卷积和空间池化），这大大增加了整个网络的感受野，因此捕获了更多的上下文。虽然我们认为在实践中，多裁剪图像的计算时间增加并不足以证明准确性的潜在收益，但作为参考，我们还在每个尺度使用 50 个裁剪图像（ 5×5 规则网格，2 次翻转）评估了我们的网络，在 3 个尺度上总共 150 个裁剪图像，与 Szegedy 等人(2014)在 4 个尺度上使用的 144 个裁剪图像。

3.3 实现细节

我们的实现来源于公开的 C++ Caffe 工具箱（Jia, 2013）（2013 年 12 月推出），但包含了一些重大的修改，使我们能够对安装在单个系统中的多个 GPU 进行训练和评估，也能训练和评估在多个尺度上（如上所述）的全尺寸（未裁剪）图像。多 GPU 训练利用数据并行性，通过将每批训练图像分成几个 GPU 批次，每个 GPU 并行处理。在计算 GPU 批次梯度之后，将其平均以获得完整批次的梯度。梯度计算在 GPU 之间是同步的，所以结果与在单个 GPU 上训练完全一样。

最近提出了更加复杂的加速 ConvNet 训练的方法（Krizhevsky, 2014），它们对网络的不同层之间采用模型和数据并行，但是我们发现我们概念上更简单的方案与使用单个 GPU 相比，在现有的 4-GPU 系统上已经达到 3.75 倍的加速。在

配备四个 NVIDIA Titan Black GPU 的系统上，根据架构训练单个网络需要 2-3 周时间。

4 分类实验

数据集。在本节中，我们介绍了 ConvNet 架构在 ILSVRC-2012 数据集（用于 ILSVRC 2012-2014 挑战）上实现的图像分类结果。数据集包括 1000 个类别的图像，并分为三组：训练集（130 万张图像）、验证集（5 万张图像）和测试集（留有类标签的 10 万张图像）。使用两个措施评估分类性能：top-1 和 top-5 错误率。前者是多分类误差，即没有被正确分类图像的比例；后者是 ILSVRC 中使用的主要评估标准，即计算为图像真实类别在前 5 个预测类别之外的比例。

对于大多数实验，我们使用验证集作为测试集。在测试集上也进行了一些实验，并将其作为 ILSVRC-2014 竞赛（Russakovsky 等，2014）“VGG”小组的输入提交到了官方的 ILSVRC 服务器。

4.1 单尺度评估

我们首先评估单个 ConvNet 模型在单尺度上的性能，其层结构配置如 2.2 节中描述。测试图像大小设置如下：对于固定 S 的 $Q=S$ ，对于抖动 $S \in [S_{\min}, S_{\max}]$ ， $Q = 0.5(S_{\min} + S_{\max})$ 。结果如表 3 所示。

表 3：测试图像单尺度的 ConvNet 性能

ConvNet config. (Table 1)	smallest image side		top-1 val. error (%)	top-5 val. error (%)
	train (S)	test (Q)		
A	256	256	29.6	10.4
A-LRN	256	256	29.7	10.5
B	256	256	28.7	9.9
C	256	256	28.1	9.4
	384	384	28.1	9.3
	[256;512]	384	27.3	8.8
D	256	256	27.0	8.8
	384	384	26.8	8.7
	[256;512]	384	25.6	8.1
E	256	256	27.3	9.0
	384	384	26.9	8.7
	[256;512]	384	25.5	8.0

首先，我们注意到，使用局部响应归一化网络（A-LRN 网络）在没有任何归一化层的情况下，对模型 A 没有改善。因此，我们在较深的架构（B-E）中不采用归一化。

第二，我们观察到分类误差随着 ConvNet 深度的增加而减小：从 A 中的 11 层到 E 中的 19 层。值得注意的是，尽管深度相同，配置 C（包含三个 1×1 卷积层）比在整个网络层中使用 3×3 卷积的配置 D 更差。这表明，虽然额外的非线性确实有帮助（C 优于 B），但也可以通过使用具有非平凡感受野（D 比 C 好）的卷积滤波器来捕获空间上下文。当深度达到 19 层时，我们架构的错误率饱和，但更深的模型可能有益于较大的数据集。我们还将网络 B 与具有 5×5 卷积层的浅层网络进行了比较，这个浅层网络可以通过用单个 5×5 卷积层替换 B 中每对 3×3 卷积层得到（如第 2.3 节所述其具有相同的感受野）。测量的浅层网络 top-1 错误率比网络 B 的 top-1 错误率（在中心裁剪图像上）高 7%，这证实了具有小滤波器的深层网络优于具有较大滤波器的浅层网络。

最后，训练时的尺度抖动（ $S \in [256; 512]$ ）与固定最小边（ $S = 256$ or $S = 384$ ）的图像训练相比更好的结果，即使在测试时使用单尺度。这证实了通过尺度抖动进行的训练集增强确实有助于捕获多尺度图像统计。

4.2 多尺度评估

在单尺度上评估 ConvNet 模型后，我们现在评估测试时尺度抖动的影响。它包括在一张测试图像的几个归一化版本上运行模型（对应于不同的 Q 值），然后对所得到的类别后验进行平均。考虑到训练和测试尺度之间的巨大差异会导致性能下降，用固定 S 训练的模型在三个测试图像尺度上进行了评估，接近于训练一次： $Q = \{S-32, S, S+32\}$ 。同时，训练时的尺度抖动允许网络在测试时应用于更广的尺度范围，所以用变量 $S \in [S_{min}; S_{max}]$ 训练的模型在更大的尺寸范围 $Q = \{S_{min}, 0.5(S_{min} + S_{max}), S_{max}\}$ 上进行评估。

表 4 中给出的结果表明，测试时的尺度抖动导致了更好的性能（与在单一尺度上相同模型的评估相比，如表 3 所示）。如前所述，最深的配置（D 和 E）表现最好，并且尺度抖动优于使用固定最小边 S 的训练。我们在验证集上的最佳单网络性能为 24.8%/7.5% top-1/top-5 的错误率（在表 4 中用粗体突出显示）。在测试集上，配置 E 实现了 7.3% top-5 的错误率。

表 4: 在多个测试尺度上的 ConvNet 性能

ConvNet config. (Table 1)	smallest image side		top-1 val. error (%)	top-5 val. error (%)
	train (S)	test (Q)		
B	256	224,256,288	28.2	9.6
C	256	224,256,288	27.7	9.2
	384	352,384,416	27.8	9.2
	[256; 512]	256,384,512	26.3	8.2
D	256	224,256,288	26.6	8.6
	384	352,384,416	26.5	8.6
	[256; 512]	256,384,512	24.8	7.5
E	256	224,256,288	26.9	8.7
	384	352,384,416	26.7	8.6
	[256; 512]	256,384,512	24.8	7.5

4.3 多裁剪图像评估

在表 5 中，我们将密集 ConvNet 评估与多裁剪图像评估进行比较（细节参见第 3.2 节）。我们还通过平均其 soft-max 输出来评估两种评估技术的互补性。可以看出，使用多裁剪图像表现比密集评估略好，而且这两种方法确实是互补的，因为它们的组合优于其中的每一种。如上所述，我们假设这是由于卷积边界条件的不同处理所造成的。

表 5: ConvNet 评估技术比较。在所有的实验中训练尺度 S 从[256; 512]采样，采用三个测试尺度 Q: {256, 384, 512}。

ConvNet config. (Table 1)	Evaluation method	top-1 val. error (%)	top-5 val. error (%)
D	dense	24.8	7.5
	multi-crop	24.6	7.5
	multi-crop & dense	24.4	7.2
E	dense	24.8	7.5
	multi-crop	24.6	7.4
	multi-crop & dense	24.4	7.1

4.4 卷积网络融合

到目前为止，我们评估了 ConvNet 模型的性能。在这部分实验中，我们对 soft-max 类别后验概率进行平均，结合了几种模型的输出。由于模型的互补性，提高了性能，并且将其在 2012 年（Krizhevsky 等，2012）和 2013 年（Zeiler & Fergus, 2013; Sermanet 等，2014）ILSVRC 的顶级提交中使用。

结果如表 6 所示。在 ILSVRC 提交的时候，我们只训练了单尺度网络，以及一个多尺度模型 D（仅在全连接层进行微调而不是所有层）。由此产生的 7 个网络集成具有 7.3% 的 ILSVRC 测试误差。在提交之后，我们采用只有两个表现最好的多尺度模型（配置 D 和 E）进行组合，使用密集评估将测试误差降低到 7.0%，

使用密集评估和多裁剪图像评估组合将测试误差降低到 6.8%。作为参考，我们表现最佳的单模型达到 7.1% 的误差（模型 E，表 5）。

表 6： 多个卷积网络融合结果

Combined ConvNet models	Error		
	top-1 val	top-5 val	top-5 test
ILSVRC submission			
(D/256/224,256,288), (D/384/352,384,416), (D/[256;512]/256,384,512) (C/256/224,256,288), (C/384/352,384,416) (E/256/224,256,288), (E/384/352,384,416)	24.7	7.5	7.3
post-submission			
(D/[256;512]/256,384,512), (E/[256;512]/256,384,512), dense eval.	24.0	7.1	7.0
(D/[256;512]/256,384,512), (E/[256;512]/256,384,512), multi-crop	23.9	7.2	-
(D/[256;512]/256,384,512), (E/[256;512]/256,384,512), multi-crop & dense eval.	23.7	6.8	6.8

4.5 与最新技术比较

最后，我们在表 7 中与最新技术比较了我们的结果。在 ILSVRC-2014 竞赛的分类任务（Russakovsky 等，2014）中，我们的“VGG”团队获得了第二名，使用 7 个模型集成取得了 7.3% 测试误差。提交后，我们使用 2 个模型集成将错误率降低到 6.8%。

表 7： 在 ILSVRC 分类中与最新技术比较。我们的方法表示为“VGG”。报告的结果没有使用外部数据。

Method	top-1 val. error (%)	top-5 val. error (%)	top-5 test error (%)
VGG (2 nets, multi-crop & dense eval.)	23.7	6.8	6.8
VGG (1 net, multi-crop & dense eval.)	24.4	7.1	7.0
VGG (ILSVRC submission, 7 nets, dense eval.)	24.7	7.5	7.3
GoogLeNet (Szegedy et al., 2014) (1 net)	-	7.9	
GoogLeNet (Szegedy et al., 2014) (7 nets)	-	6.7	
MSRA (He et al., 2014) (11 nets)	-	-	8.1
MSRA (He et al., 2014) (1 net)	27.9	9.1	9.1
Clarifai (Russakovsky et al., 2014) (multiple nets)	-	-	11.7
Clarifai (Russakovsky et al., 2014) (1 net)	-	-	12.5
Zeiler & Fergus (Zeiler & Fergus, 2013) (6 nets)	36.0	14.7	14.8
Zeiler & Fergus (Zeiler & Fergus, 2013) (1 net)	37.5	16.0	16.1
OverFeat (Sermanet et al., 2014) (7 nets)	34.0	13.2	13.6
OverFeat (Sermanet et al., 2014) (1 net)	35.7	14.2	-
Krizhevsky et al. (Krizhevsky et al., 2012) (5 nets)	38.1	16.4	16.4
Krizhevsky et al. (Krizhevsky et al., 2012) (1 net)	40.7	18.2	-

从表 7 可以看出，我们非常深的 ConvNets 显著优于前几代在 ILSVRC-2012 和 ILSVRC-2013 竞赛中取得了最好结果的模型。我们的结果相对于分类任务获胜者（GoogLeNet 具有 6.7% 的错误率）也具有竞争力，并且大大优于 ILSVRC-2013 获胜者 Clarifai 的提交，其使用外部训练数据取得了 11.2% 的错误率，没有外部数据则为 11.7%。这是非常显著的，考虑到我们最好的结果是仅通过组合两个模型实现的——明显少于大多数 ILSVRC 提交。在单网络性能方面，我们的架

构取得了最好结果（7.0%测试误差），超过单个 GoogLeNet 0.9%。值得注意的是，我们并没有偏离 LeCun（1989）等人经典的 ConvNet 架构，但通过大幅增加深度改善了它。

5 结论

在这项工作中，我们评估了非常深的卷积网络（最多 19 个权重层）用于大规模图像分类。已经证明，表示深度有利于分类精度，并且深度大大增加的传统 ConvNet 架构（LeCun 等，1989；Krizhevsky 等，2012）可以实现 ImageNet 挑战数据集上的最佳性能。在附录中，我们还呈现了我们的模型很好地泛化到各种各样的任务和数据集上，可以匹敌或超越更复杂的识别流程，其构建围绕不深的图像表示。我们的结果再次证实了深度在视觉表示中的重要性。

致谢

这项工作得到 ERC 授权的 VisRec 编号 228180 的支持。我们非常感谢 NVIDIA 公司为本研究捐赠的 GPU。

参考文献

1. Bell, S., Upchurch, P., Snavely, N., and Bala, K. Material recognition in the wild with the materials in context database. CoRR, abs/1412.0623, 2014.
2. Chatfield, K., Simonyan, K., Vedaldi, A., and Zisserman, A. Return of the devil in the details: Delving deep into convolutional nets. In Proc. BMVC., 2014.
3. Cimpoi, M., Maji, S., and Vedaldi, A. Deep convolutional filter banks for texture recognition and segmentation. CoRR, abs/1411.6836, 2014.
4. Ciresan, D. C., Meier, U., Masci, J., Gambardella, L. M., and Schmidhuber, J. Flexible, high performance convolutional neural networks for image classification. In IJCAI, pp. 1237 – 1242, 2011.
5. Dean, J., Corrado, G., Monga, R., Chen, K., Devin, M., Mao, M., Ranzato, M., Senior, A., Tucker, P., Yang, K., Le, Q. V., and Ng, A. Y. Large scale distributed deep networks. In NIPS, pp. 1232 – 1240, 2012.

6. Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. Imagenet: A large-scale hierarchical image database. In Proc. CVPR, 2009.
7. Donahue, J., Jia, Y., Vinyals, O., Hoffman, J., Zhang, N., Tzeng, E., and Darrell, T. Decaf: A deep convolutional activation feature for generic visual recognition. CoRR, abs/1310.1531, 2013.
8. Everingham, M., Eslami, S. M. A., Van Gool, L., Williams, C., Winn, J., and Zisserman, A. The Pascal visual object classes challenge: A retrospective. IJCV, 111(1):98 – 136, 2015.
9. Fei-Fei, L., Fergus, R., and Perona, P. Learning generative visual models from few training examples: An incremental bayesian approach tested on 101 object categories. In IEEE CVPR Workshop of Generative Model Based Vision, 2004.
10. Girshick, R. B., Donahue, J., Darrell, T., and Malik, J. Rich feature hierarchies for accurate object detection and semantic segmentation. CoRR, abs/1311.2524v5, 2014. Published in Proc. CVPR, 2014.
11. Gkioxari, G., Girshick, R., and Malik, J. Actions and attributes from wholes and parts. CoRR, abs/1412.2604, 2014.
12. Glorot, X. and Bengio, Y. Understanding the difficulty of training deep feedforward neural networks. In Proc. AISTATS, volume 9, pp. 249 – 256, 2010.
13. Goodfellow, I. J., Bulatov, Y., Ibarz, J., Arnoud, S., and Shet, V. Multi-digit number recognition from street view imagery using deep convolutional neural networks. In Proc. ICLR, 2014.
14. Griffin, G., Holub, A., and Perona, P. Caltech-256 object category dataset. Technical Report 7694, California Institute of Technology, 2007.
15. He, K., Zhang, X., Ren, S., and Sun, J. Spatial pyramid pooling in deep convolutional networks for visual recognition. CoRR, abs/1406.4729v2, 2014.
16. Hoai, M. Regularized max pooling for image categorization. In Proc. BMVC., 2014.

17. Howard, A. G. Some improvements on deep convolutional neural network based image classification. In Proc. ICLR, 2014.
18. Jia, Y. Caffe: An open source convolutional architecture for fast feature embedding. <http://caffe.berkeleyvision.org/>, 2013.
19. Karpathy, A. and Fei-Fei, L. Deep visual-semantic alignments for generating image descriptions. CoRR, abs/1412.2306, 2014.
20. Kiros, R., Salakhutdinov, R., and Zemel, R. S. Unifying visual-semantic embeddings with multimodal neural language models. CoRR, abs/1411.2539, 2014.
21. Krizhevsky, A. One weird trick for parallelizing convolutional neural networks. CoRR, abs/1404.5997, 2014.
22. Krizhevsky, A., Sutskever, I., and Hinton, G. E. ImageNet classification with deep convolutional neural networks. In NIPS, pp. 1106 – 1114, 2012.
23. LeCun, Y., Boser, B., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W., and Jackel, L. D. Backpropagation applied to handwritten zip code recognition. Neural Computation, 1(4):541 – 551, 1989.
24. Lin, M., Chen, Q., and Yan, S. Network in network. In Proc. ICLR, 2014.
25. Long, J., Shelhamer, E., and Darrell, T. Fully convolutional networks for semantic segmentation. CoRR, abs/1411.4038, 2014.
26. Oquab, M., Bottou, L., Laptev, I., and Sivic, J. Learning and Transferring Mid-Level Image Representations using Convolutional Neural Networks. In Proc. CVPR, 2014.
27. Perronnin, F., Sánchez, J., and Mensink, T. Improving the Fisher kernel for large-scale image classification. In Proc. ECCV, 2010.
28. Razavian, A., Azizpour, H., Sullivan, J., and Carlsson, S. CNN Features off-the-shelf: an Astounding Baseline for Recognition. CoRR, abs/1403.6382, 2014.

29. Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C., and Fei-Fei, L. ImageNet large scale visual recognition challenge. CoRR, abs/1409.0575, 2014.
30. Sermanet, P., Eigen, D., Zhang, X., Mathieu, M., Fergus, R., and LeCun, Y. OverFeat: Integrated Recognition, Localization and Detection using Convolutional Networks. In Proc. ICLR, 2014.
31. Simonyan, K. and Zisserman, A. Two-stream convolutional networks for action recognition in videos. CoRR, abs/1406.2199, 2014. Published in Proc. NIPS, 2014.
32. Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., and Rabinovich, A. Going deeper with convolutions. CoRR, abs/1409.4842, 2014.
33. Wei, Y., Xia, W., Huang, J., Ni, B., Dong, J., Zhao, Y., and Yan, S. CNN: Single-label to multi-label. CoRR, abs/1406.5726, 2014.
34. Zeiler, M. D. and Fergus, R. Visualizing and understanding convolutional networks. CoRR, abs/1311.2901, 2013. Published in Proc. ECCV, 2014.